

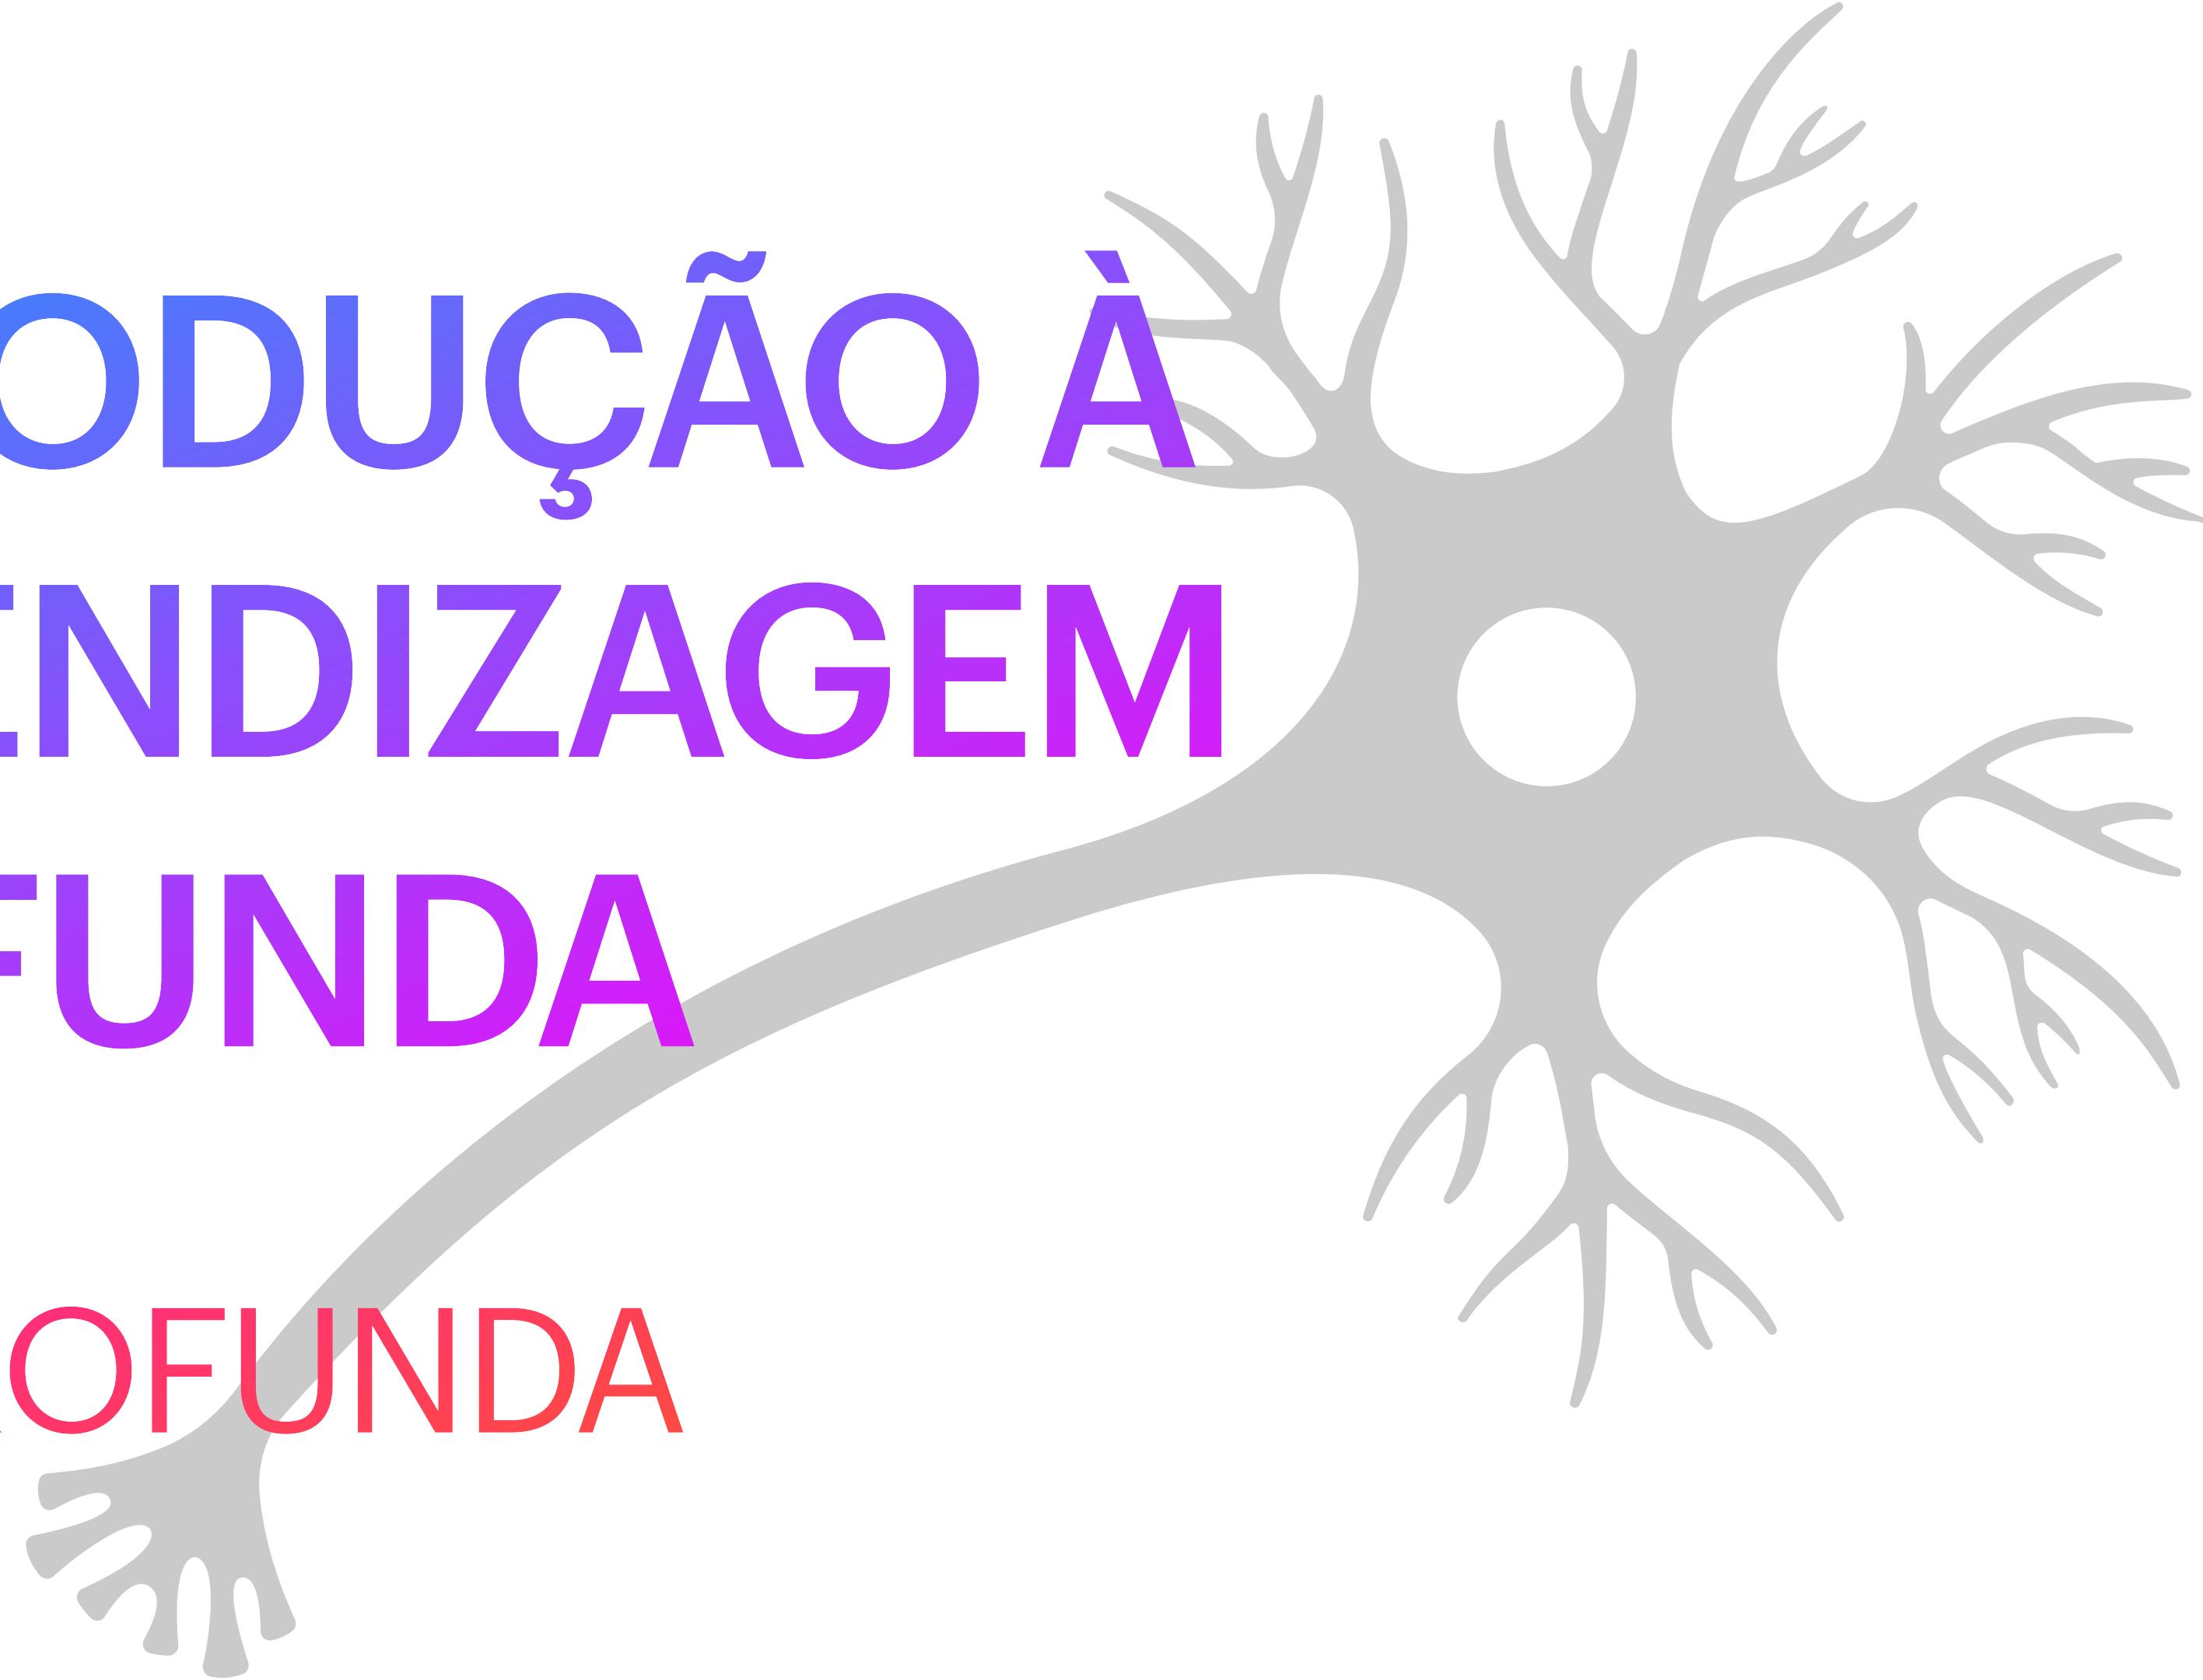
01

# INTRODUÇÃO À APRENDIZAGEM PROFUNDA

## APRENDIZAGEM PROFUNDA

PPGCC – 2023.1

Prof. Saulo Oliveira <[saulo.oliveira@ifce.edu.br](mailto:saulo.oliveira@ifce.edu.br)>



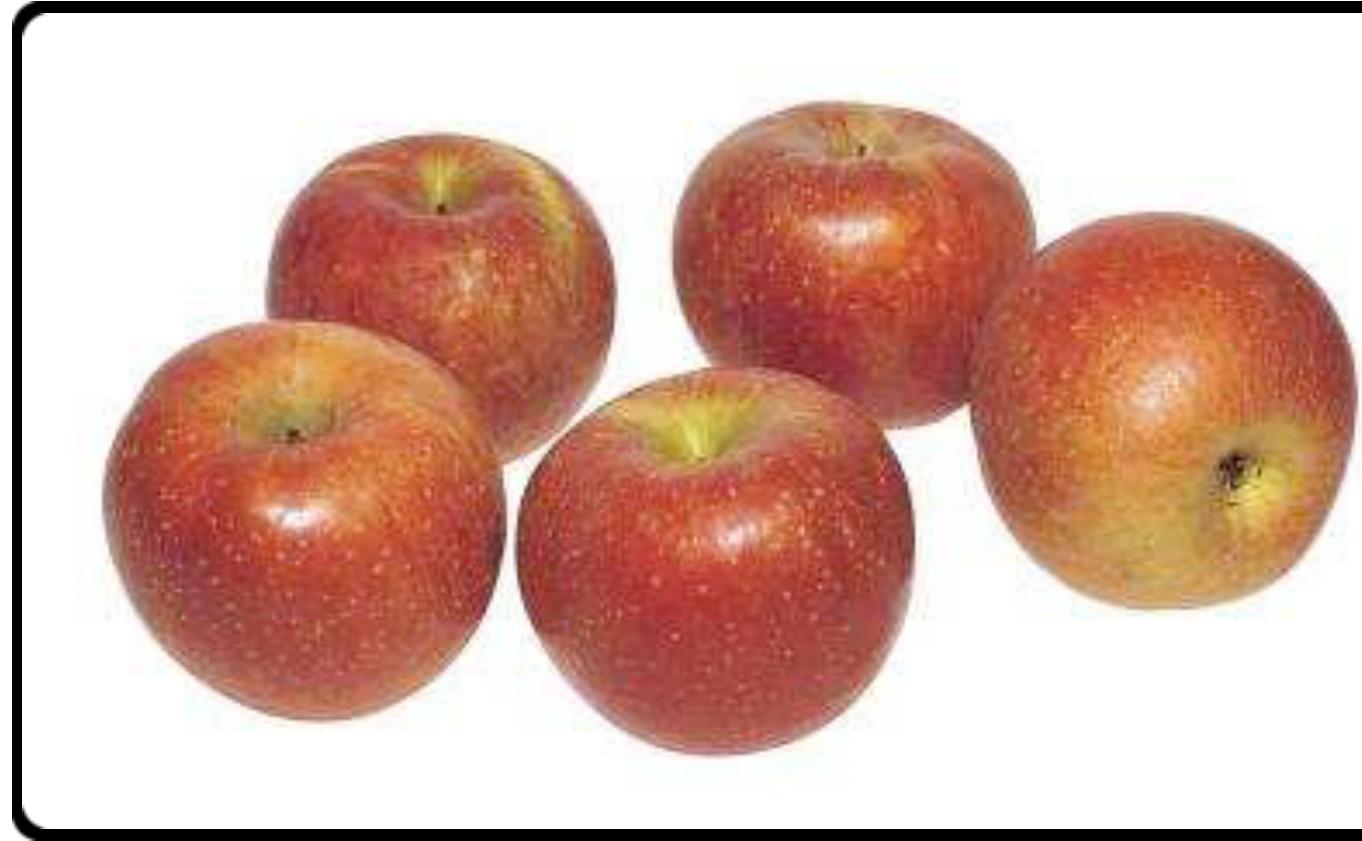
# O que é ser inteligente?



# Inteligência e reconhecimento de padrões



(A)

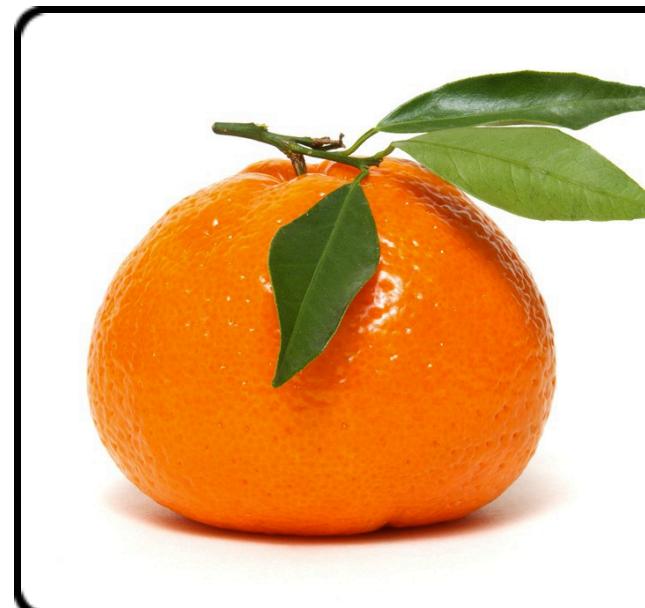


(B)



(C)

Em qual dos grupos acima você colocaria o objeto ao lado?



SIMILARIDADE  
entre a fruta  
desconhecida  
e as conhecidas.

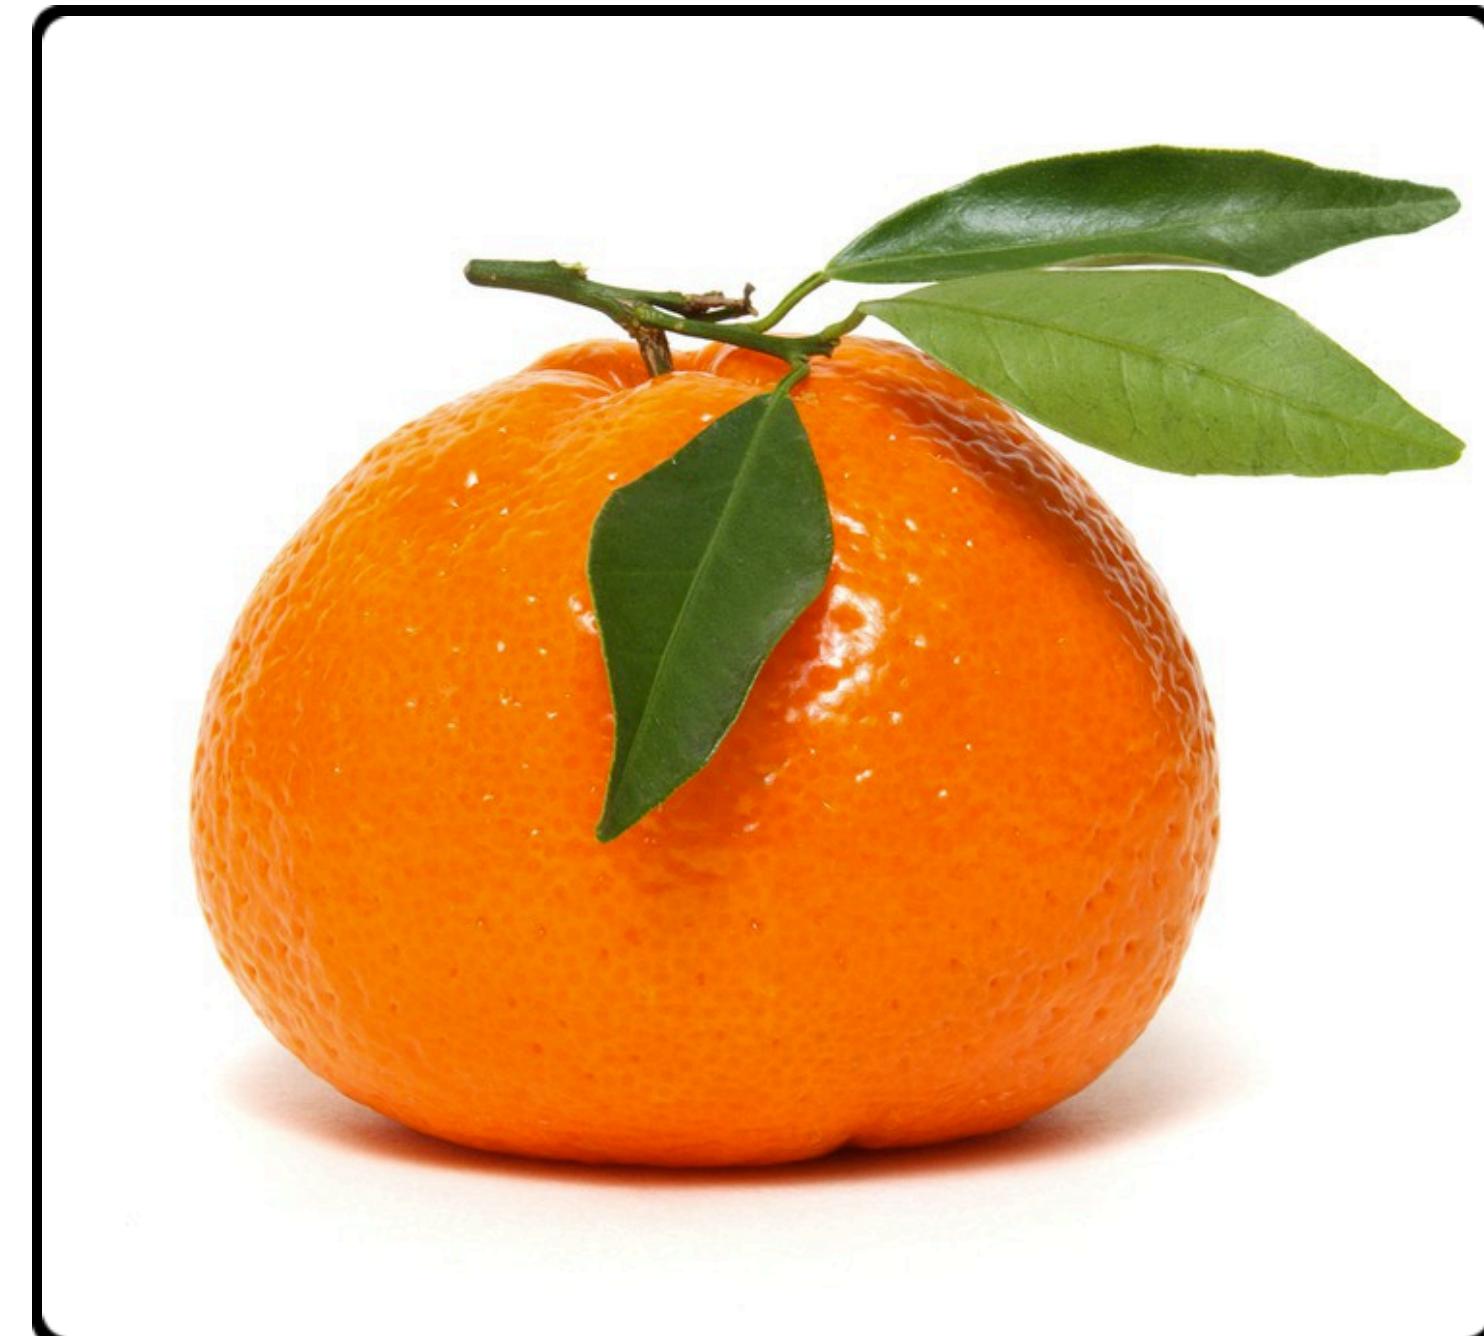
# O quê uma MÁQUINA precisa para RECONHECER PADRÓES?

- Uma **representação** dos atributos físicos das frutas;
- Uma **memória** para armazenar as frutas já aprendidas;
- Uma **regra de decisão** para classificar frutas;
- Um **aprendizado** para introduzir novas frutas.



# Quais atributos podem descrever uma Tangerina?

- Qual seu formato?  
**Oval.**
- É uma fruta cítrica?  
**Cítrico.**
- Qual a sua cor?  
**Alaranjada.**
- Qual a textura da casca?  
**Rugosa.**
- Seu cheiro é ativo ou não?  
**Ativo.**



# Como transformar os atributos físicos da tangerina em números?

- Temos que representar cada objeto como um vetor de  $p$  atributos numéricos!

$$\mathbf{x} = [x_1, x_2, \dots, x_p]^T$$

- Assim, o objeto (tangerina) será representado como:

$$\mathbf{x} = [0, 1, 2, 1, 1]^T$$

- Para isso, foi definida e utilizada a seguinte convenção,

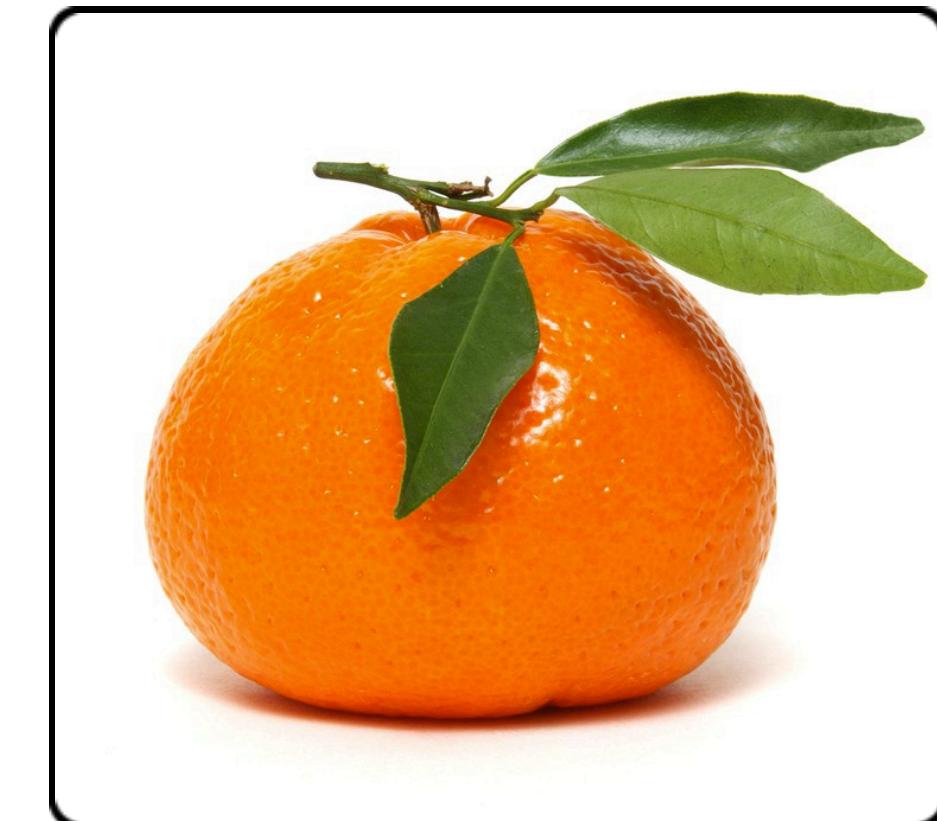
$x_1$ : {esférico, oval, alongado} = {0,1,2}

$x_2$ : {não, sim} = {0,1}

$x_3$ : {amarelo, vermelho, alaranjado, verde, marrom } = {0,1,2,3,4}

$x_4$ : {lisa, rugosa, espinhosa} = {0,1,2}

$x_5$ : {não, sim} = {0,1}



# Com base no mapeamento de atributos, como computar semelhança?

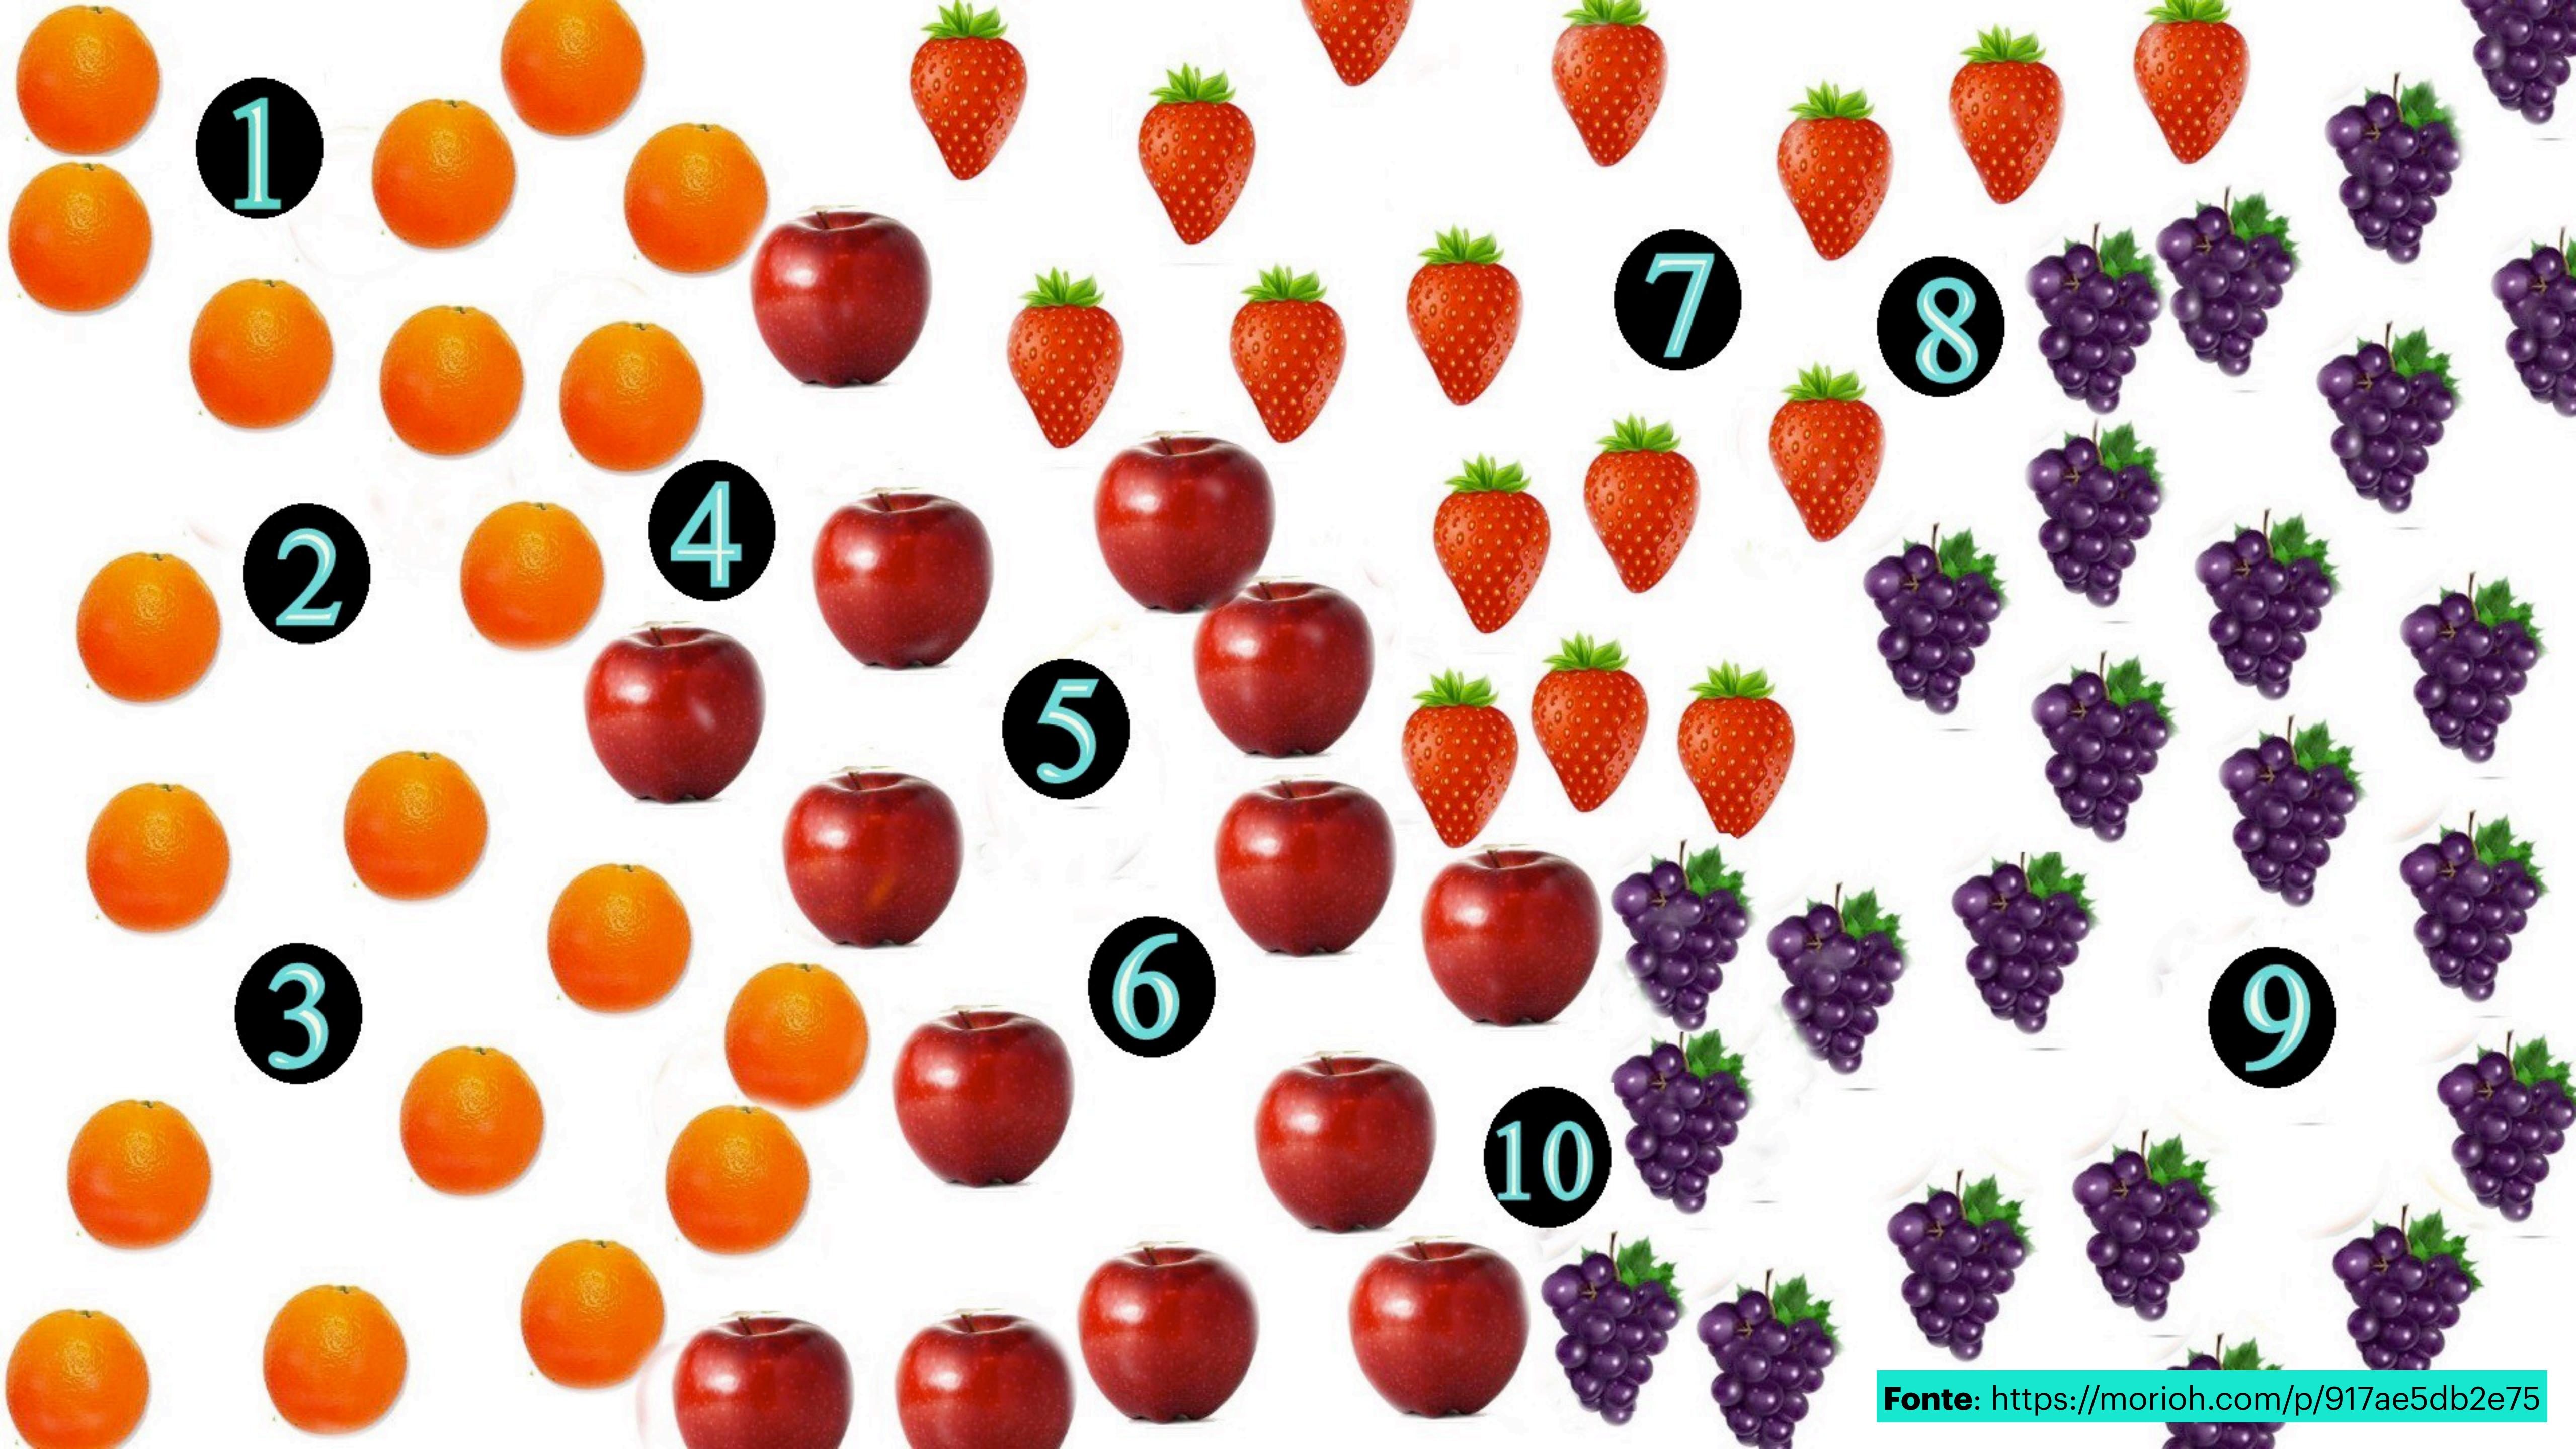
Usando a convenção anteriormente estabelecida para os atributos, temos algo do tipo,

- Laranja:  $\mathbf{x} = [0, 1, 2, 1, 0]$
- Maçã:  $\mathbf{y} = [0, 0, 1, 0, 0]$
- Tangerina:  $\mathbf{z} = [0, 1, 2, 1, 1]$

$x_1$ : {esférico, oval, alongado}  
 $x_2$ : {não, sim}  
 $x_3$ : {amarelo, vermelho, alaranjado, verde, marrom }  
 $x_4$ : {lisa, rugosa, espinhosa}  
 $x_5$ : {não, sim}

O objeto  $\mathbf{z}$  se assemelha mais a  $\mathbf{x}$  ou a  $\mathbf{y}$ ? Ou seja,

- $\mathbf{z} = [0, 1, 2, 1, 1]$  está mais próximo de  $\mathbf{x} = [0, 1, 2, 1, 0]$ ?
- Ou  $\mathbf{z} = [0, 1, 2, 1, 1]$  está mais próximo de  $\mathbf{y} = [0, 0, 1, 0, 0]$ ?



# Medidas de (dis)similaridade

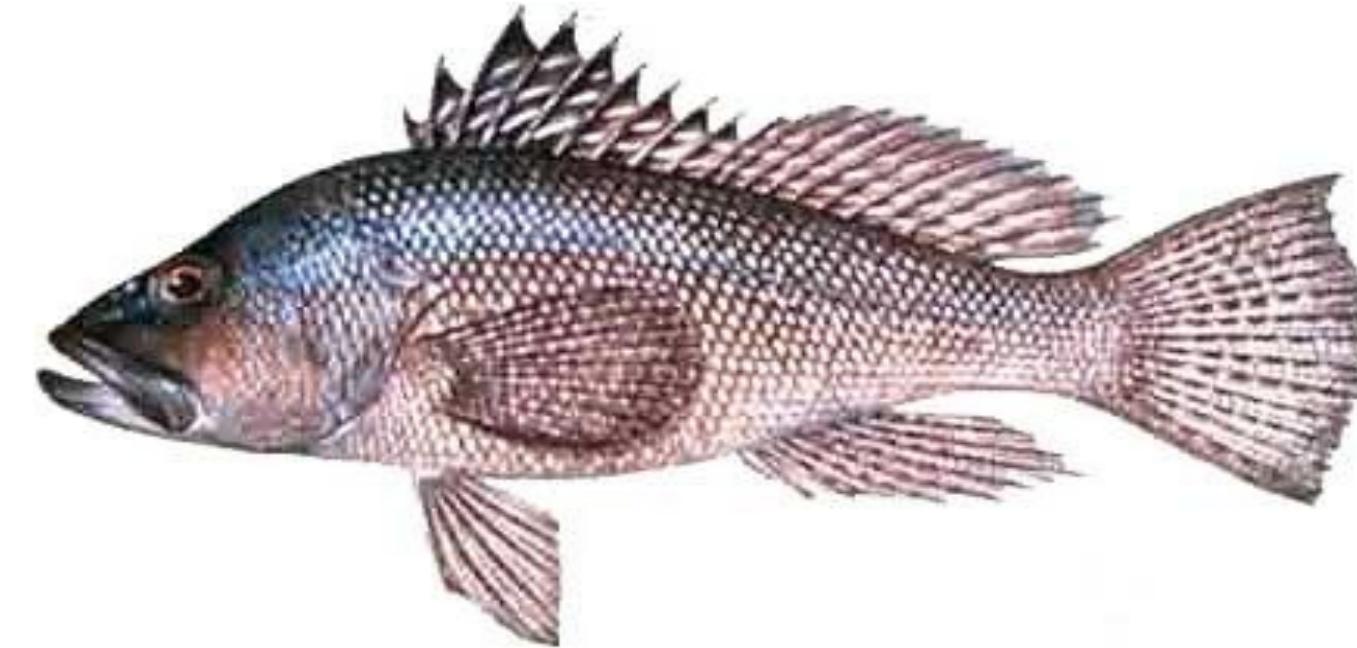
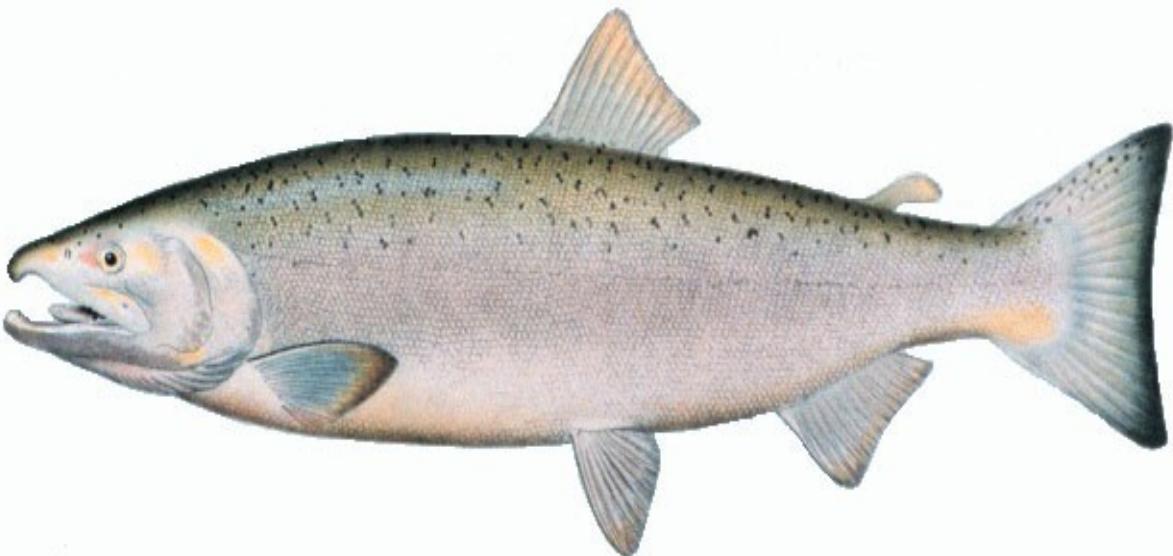
- Considerando os vetores abaixo,
  - Laranja:  $\mathbf{x} = [0, 1, 2, 1, 0]$
  - Maçã:  $\mathbf{y} = [0, 0, 1, 0, 0]$
  - Tangerina:  $\mathbf{z} = [0, 1, 2, 1, 1]$
- A distância quarteirão entre dois vetores quaisquer  $\mathbf{a}$  e  $\mathbf{b}$  é definida como:
$$\text{dist}(\mathbf{a}, \mathbf{b}) = \sum_{i=1}^p |a_i - b_i| = |a_1 - b_1| + |a_2 - b_2| + \dots + |a_p - b_p|.$$
- Qual amostra possui a menor distância entre  $\mathbf{z}$ ,  $\text{dist}(\mathbf{x}, \mathbf{z})$  ou  $\text{dist}(\mathbf{y}, \mathbf{z})$ ?



# SALMÃO × ROBALO

O verdadeiro *Hello World!*

# Teoria da decisão (rascunho)



Salmão (posta) 200g  
R\$44,50

Cerca de 90% do salmão consumido no Brasil é originado do Chile, onde são criados em fazendas marinhas. É um dos peixes mais apreciados na gastronomia, por seu sabor suave e cor especial.

Postas de aproximadamente 200 gramas não embalados individualmente.

Selecione quantas postas deseja comprar.



Filé de Peixe Robalo Congelado – 1 kg  
R\$110,00

Robalo em filé (R\$ 110,00 Kg).

Embalagem de 1 Kg (em média 6 filés). Pode ter variação de peso e quantidade de filés por pacote.

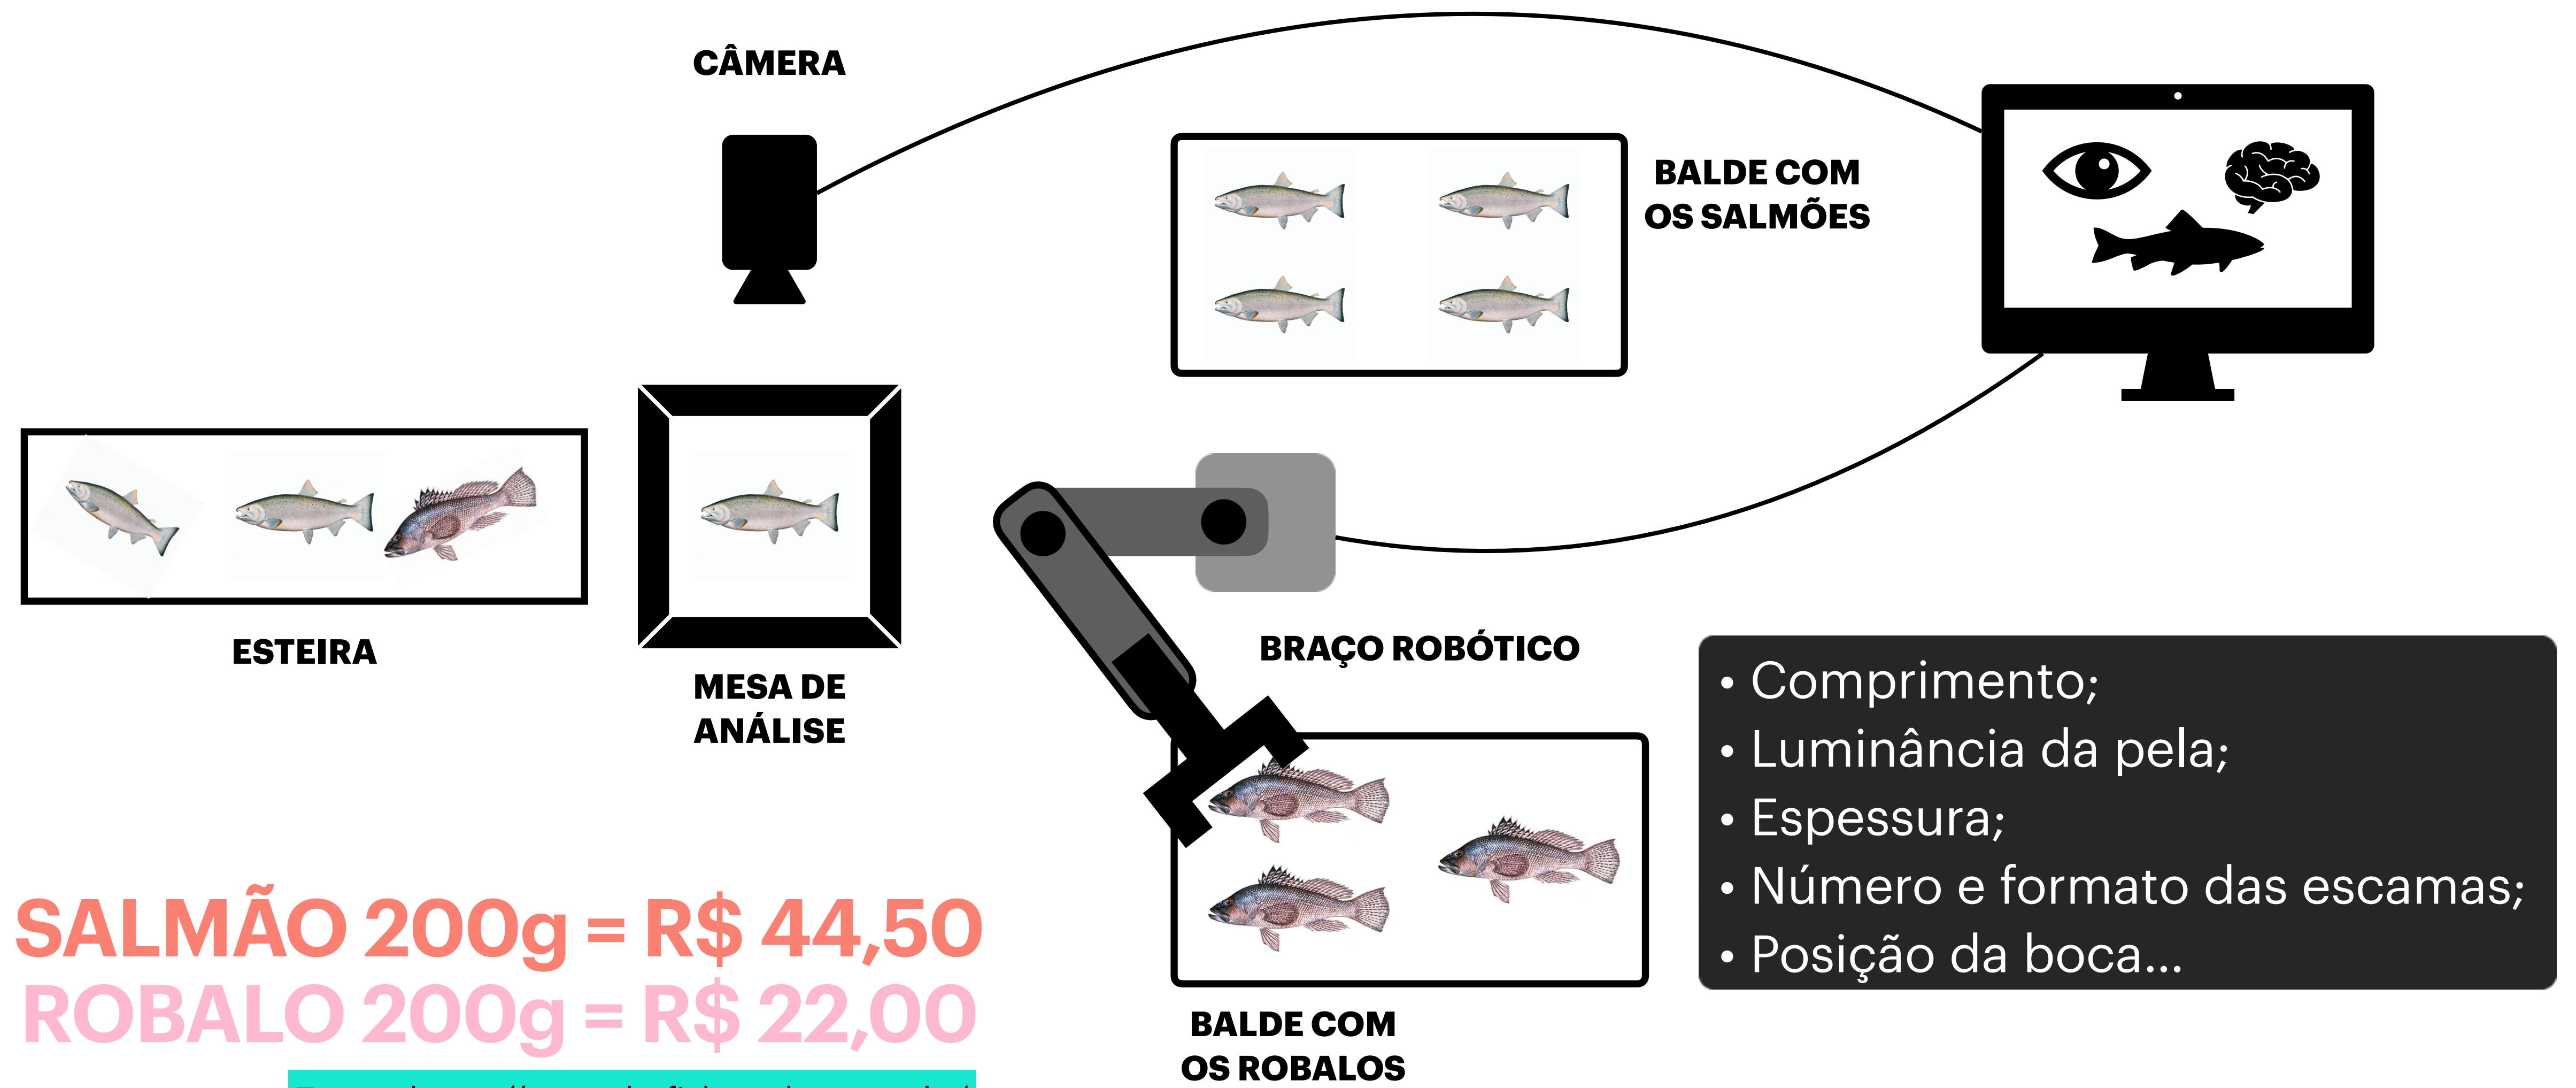
Seus produtos serão pesados e entraremos em contato para informar o valor final, data de entrega e forma de pagamento.

Escolha a quantidade desejada e faça seu pedido.

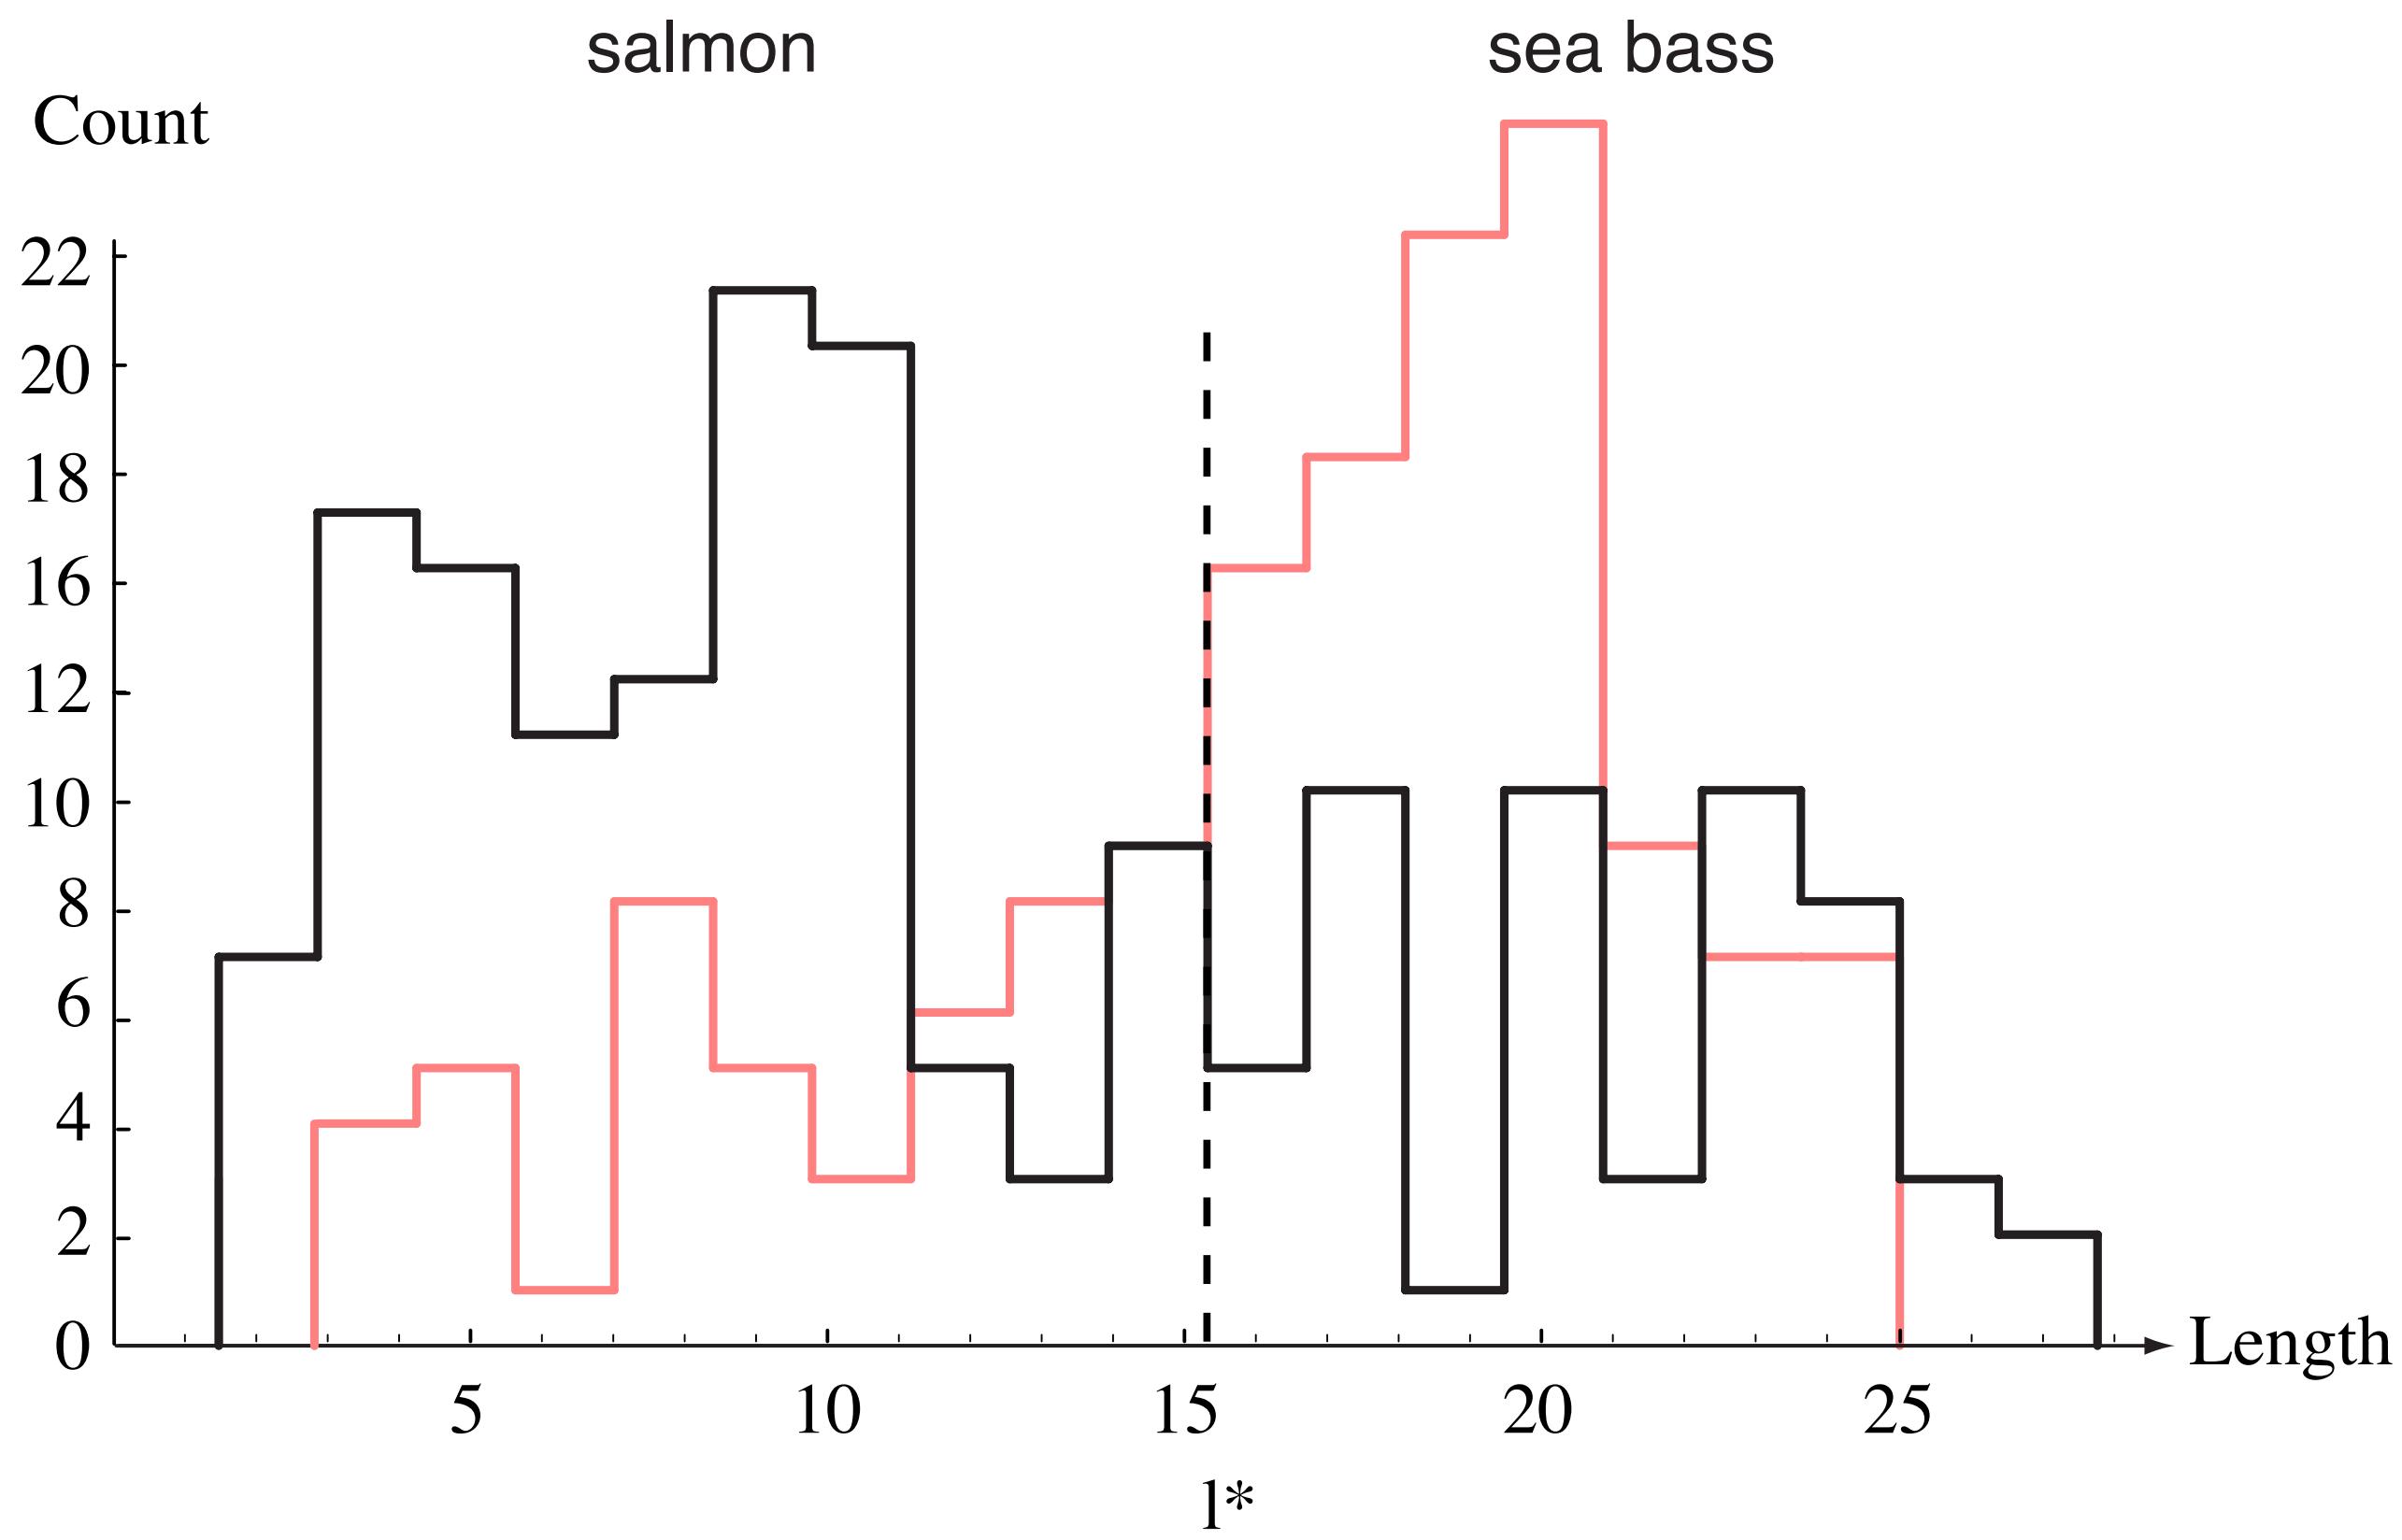
**SALMÃO 200g = R\$ 44,50**  
**ROBALO 200g = R\$ 22,00**

**Fonte:** <https://www.thefishmarket.com.br/>

# Hello World: Sistema de separação de pescados



# Teoria da decisão (rascunho)



Salmão (posta) 200g

R\$44,50

Cerca de 90% do salmão consumido no Brasil é originado do Chile, onde são criados em fazendas marinhais. É um dos peixes mais apreciados na gastronomia, por seu sabor suave e cor especial.

Postas de aproximadamente 200 gramas não embalados individualmente.

Selecione quantas postas deseja comprar.



Filé de Peixe Robalo Congelado – 1 kg

R\$110,00

Robalo em filé (R\$ 110,00 Kg).

Embalagem de 1 Kg (em média 6 filés). Pode ter variação de peso e quantidade de filés por pacote.

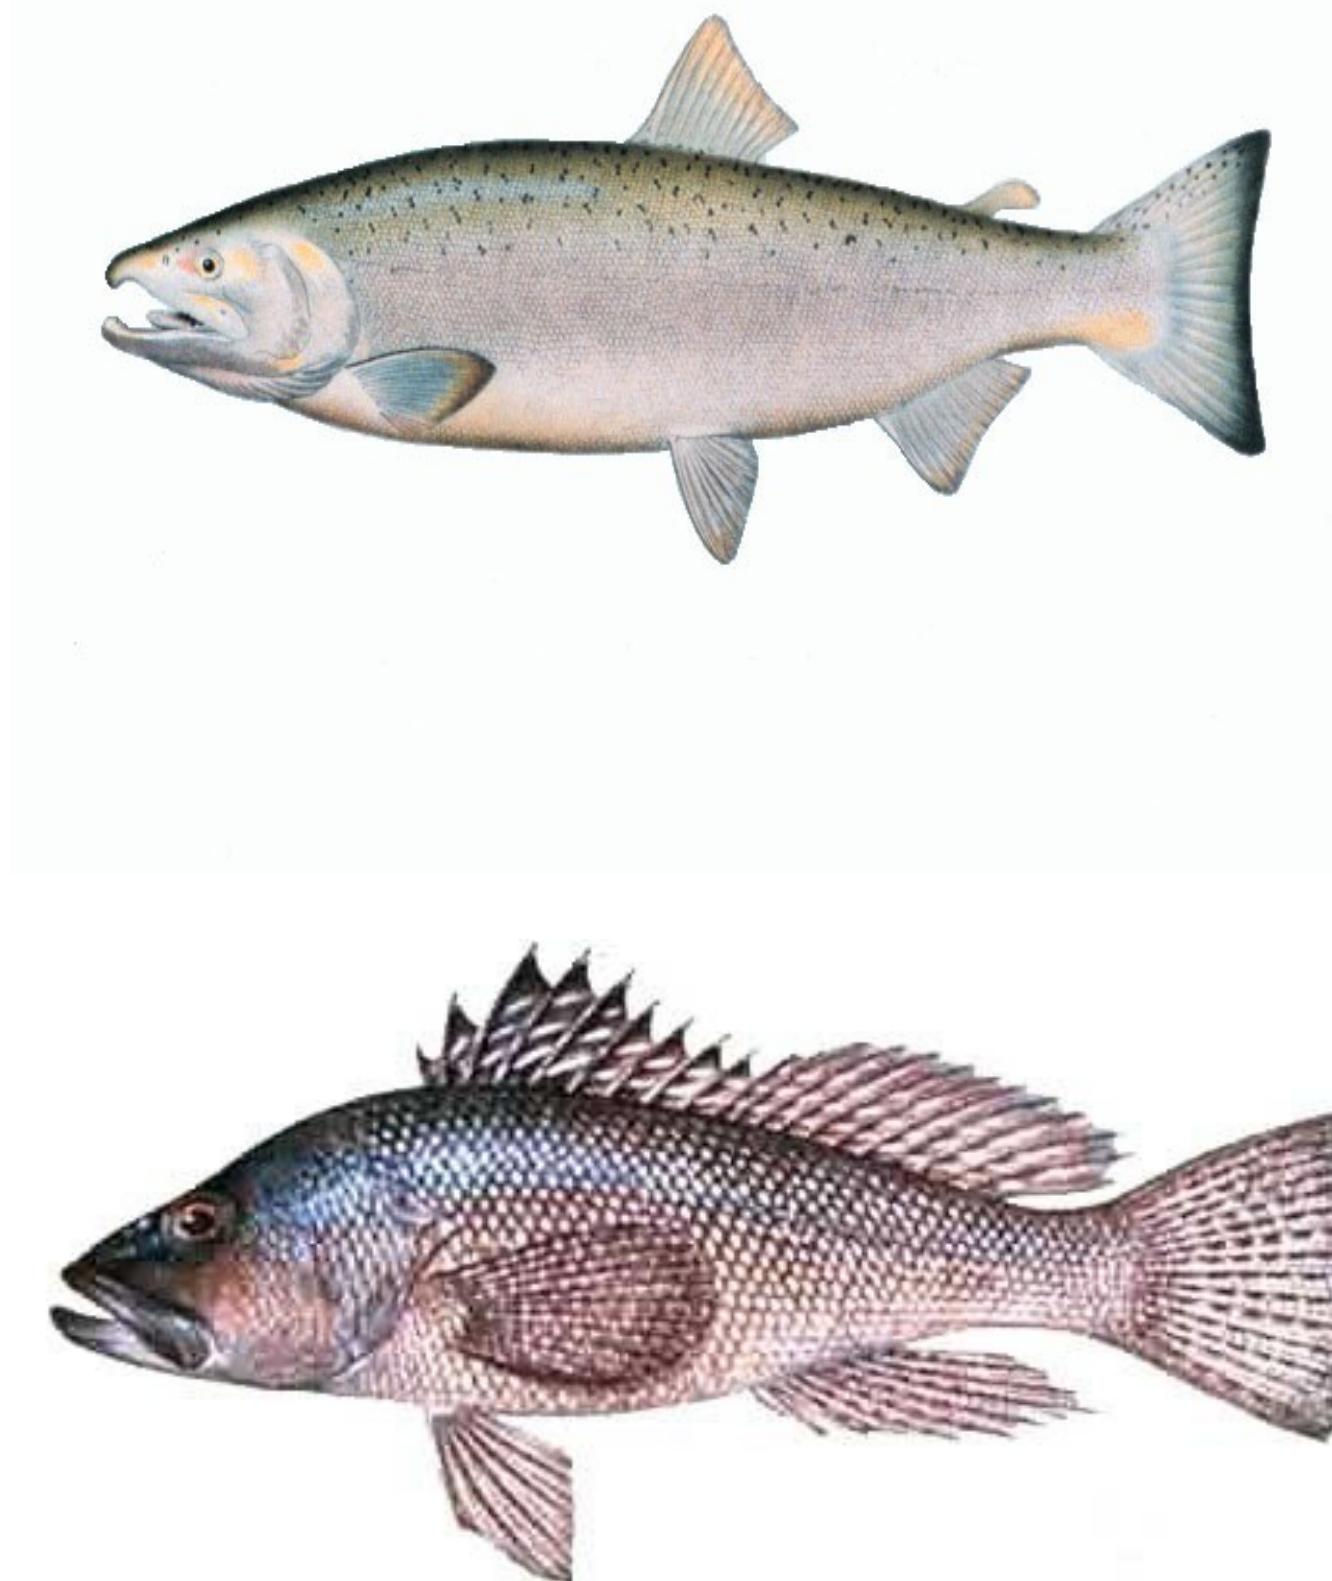
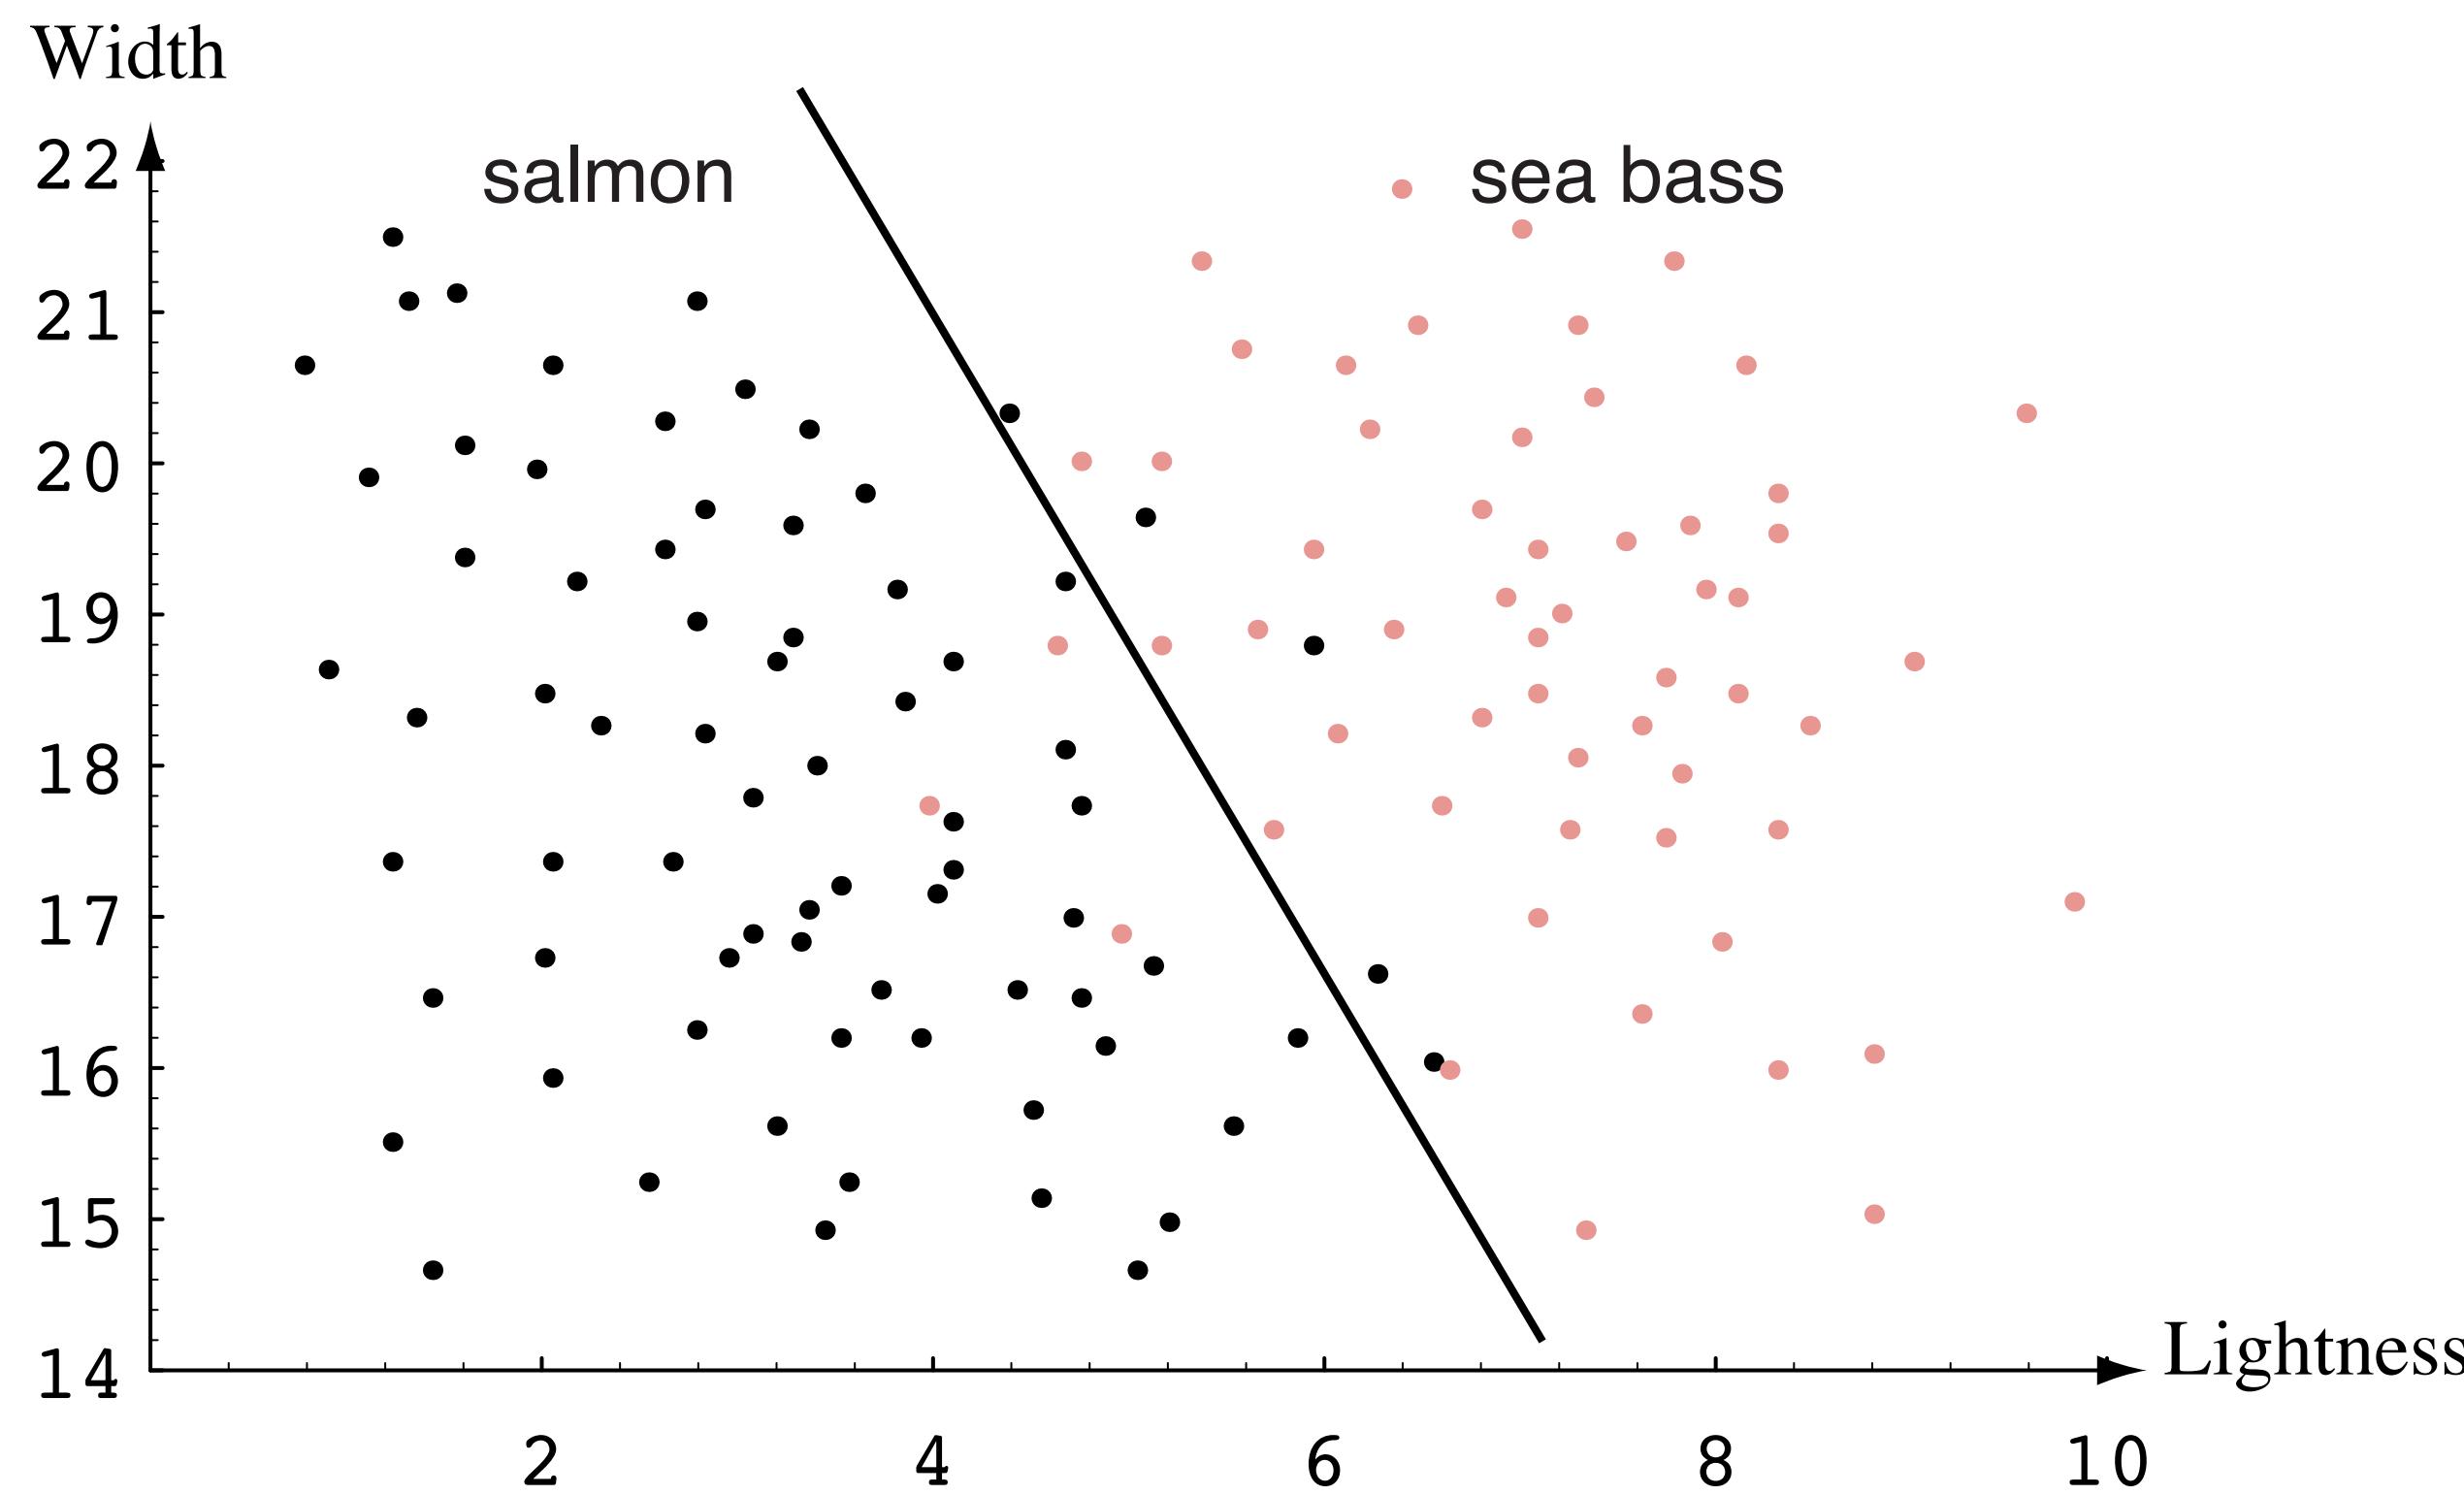
Seus produtos serão pesados e entraremos em contato para informar o valor final, data de entrega e forma de pagamento.

Escolha a quantidade desejada e faça seu pedido.

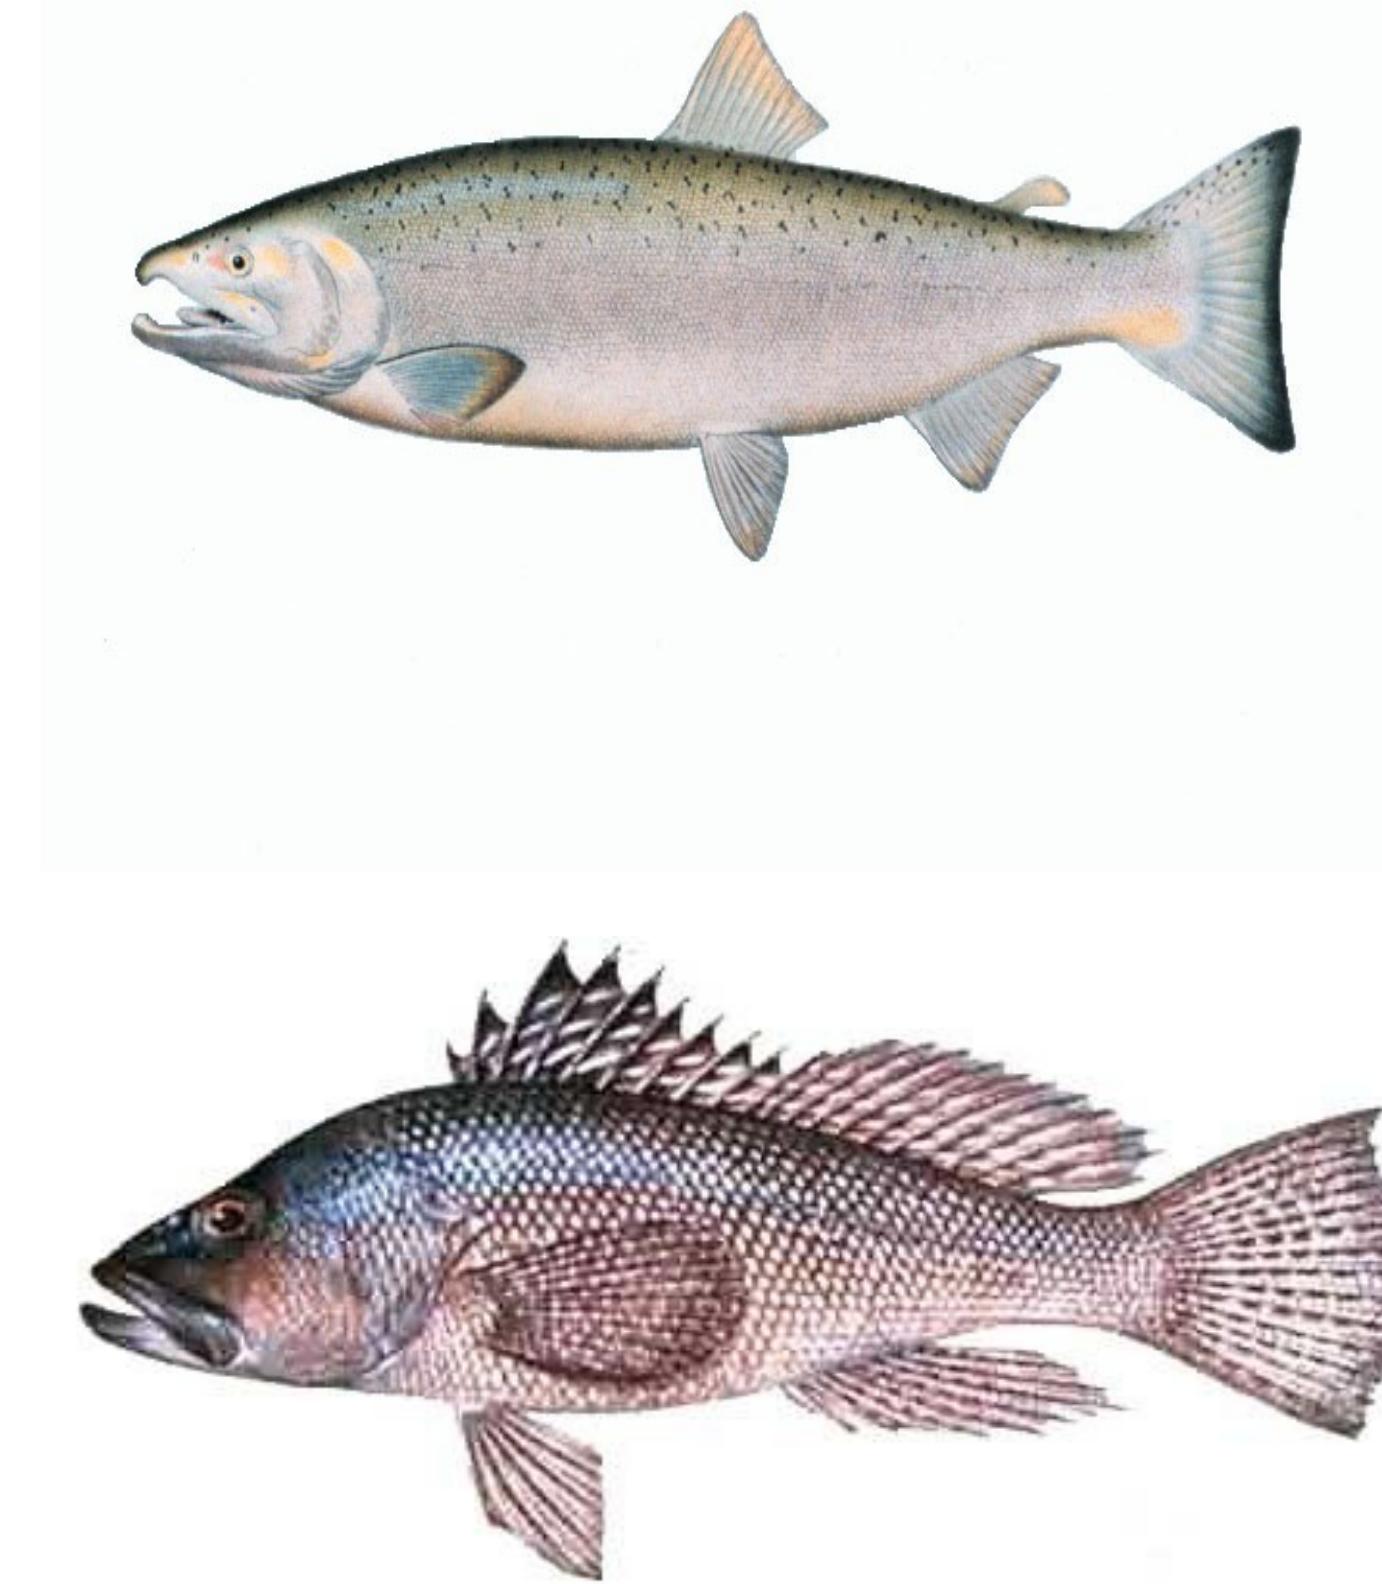
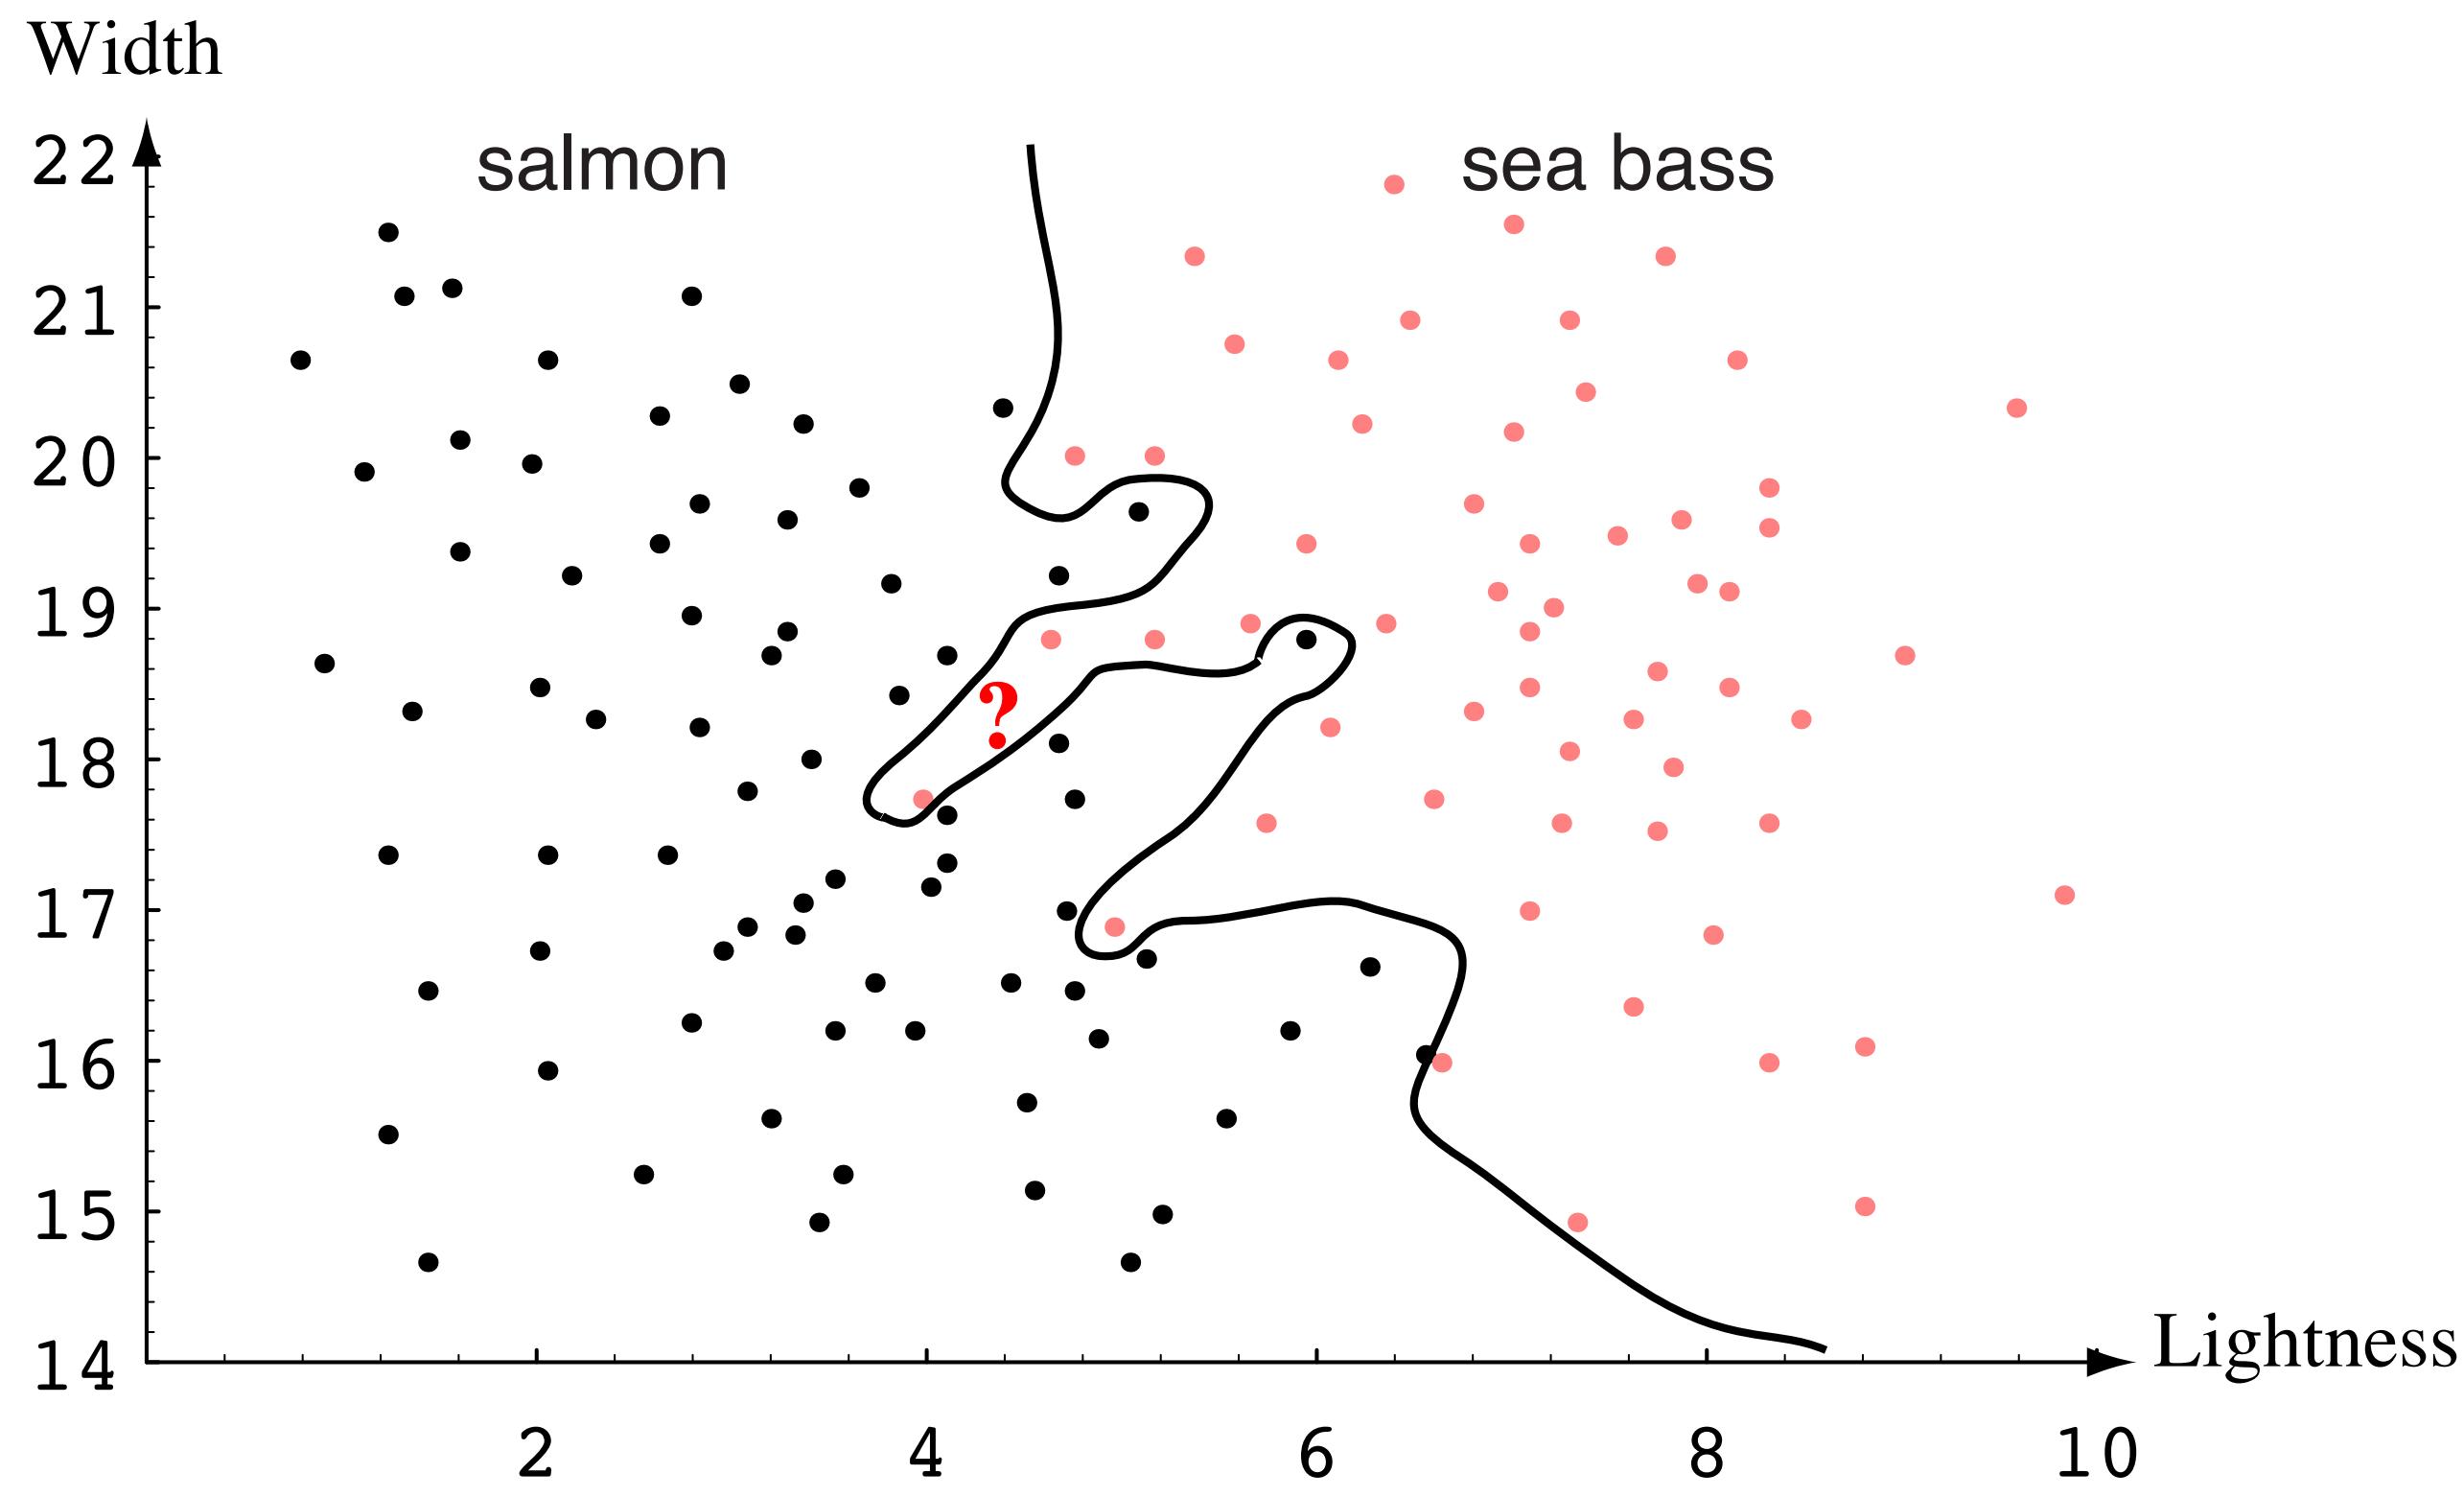
**SALMÃO 200g = R\$ 44,50**  
**ROBALO 200g = R\$ 22,00**

Fonte: <https://www.thefishmarket.com.br/>

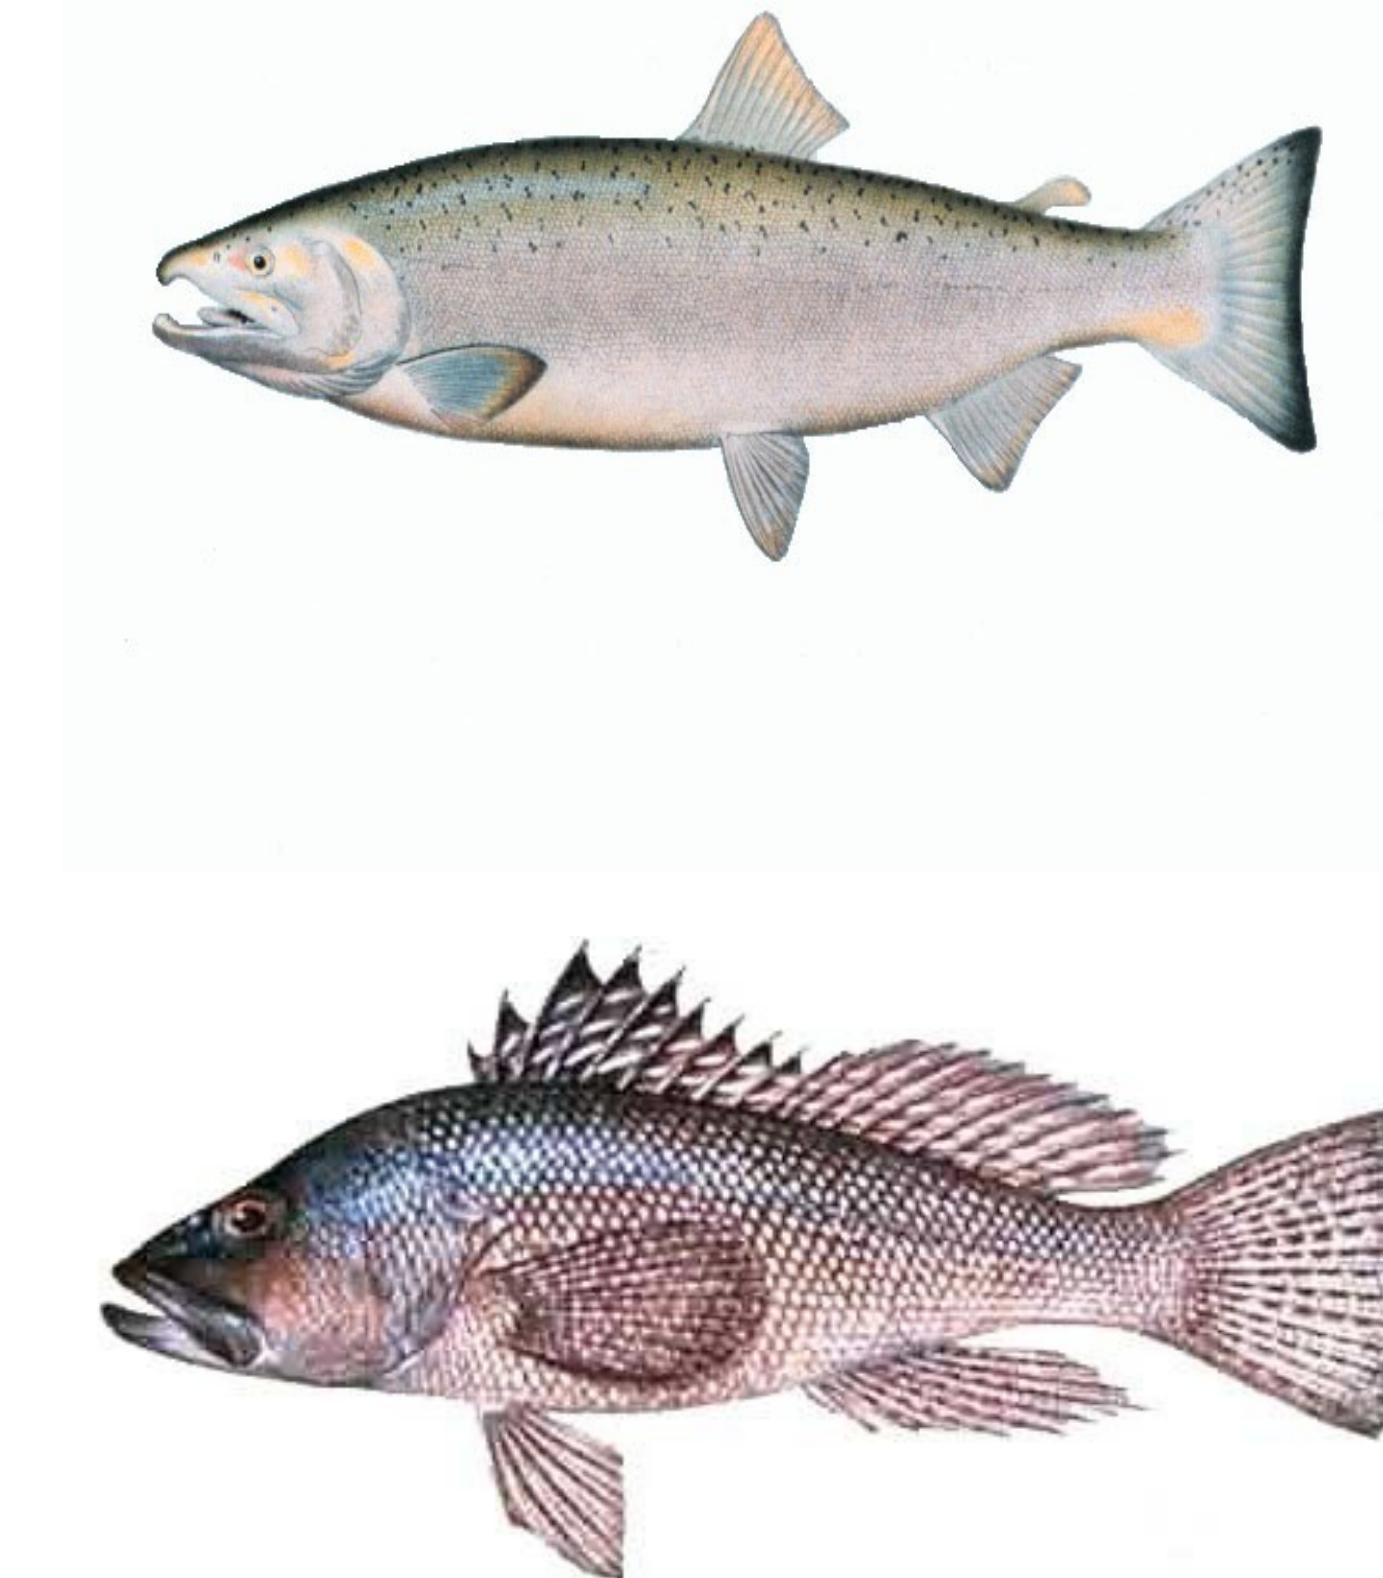
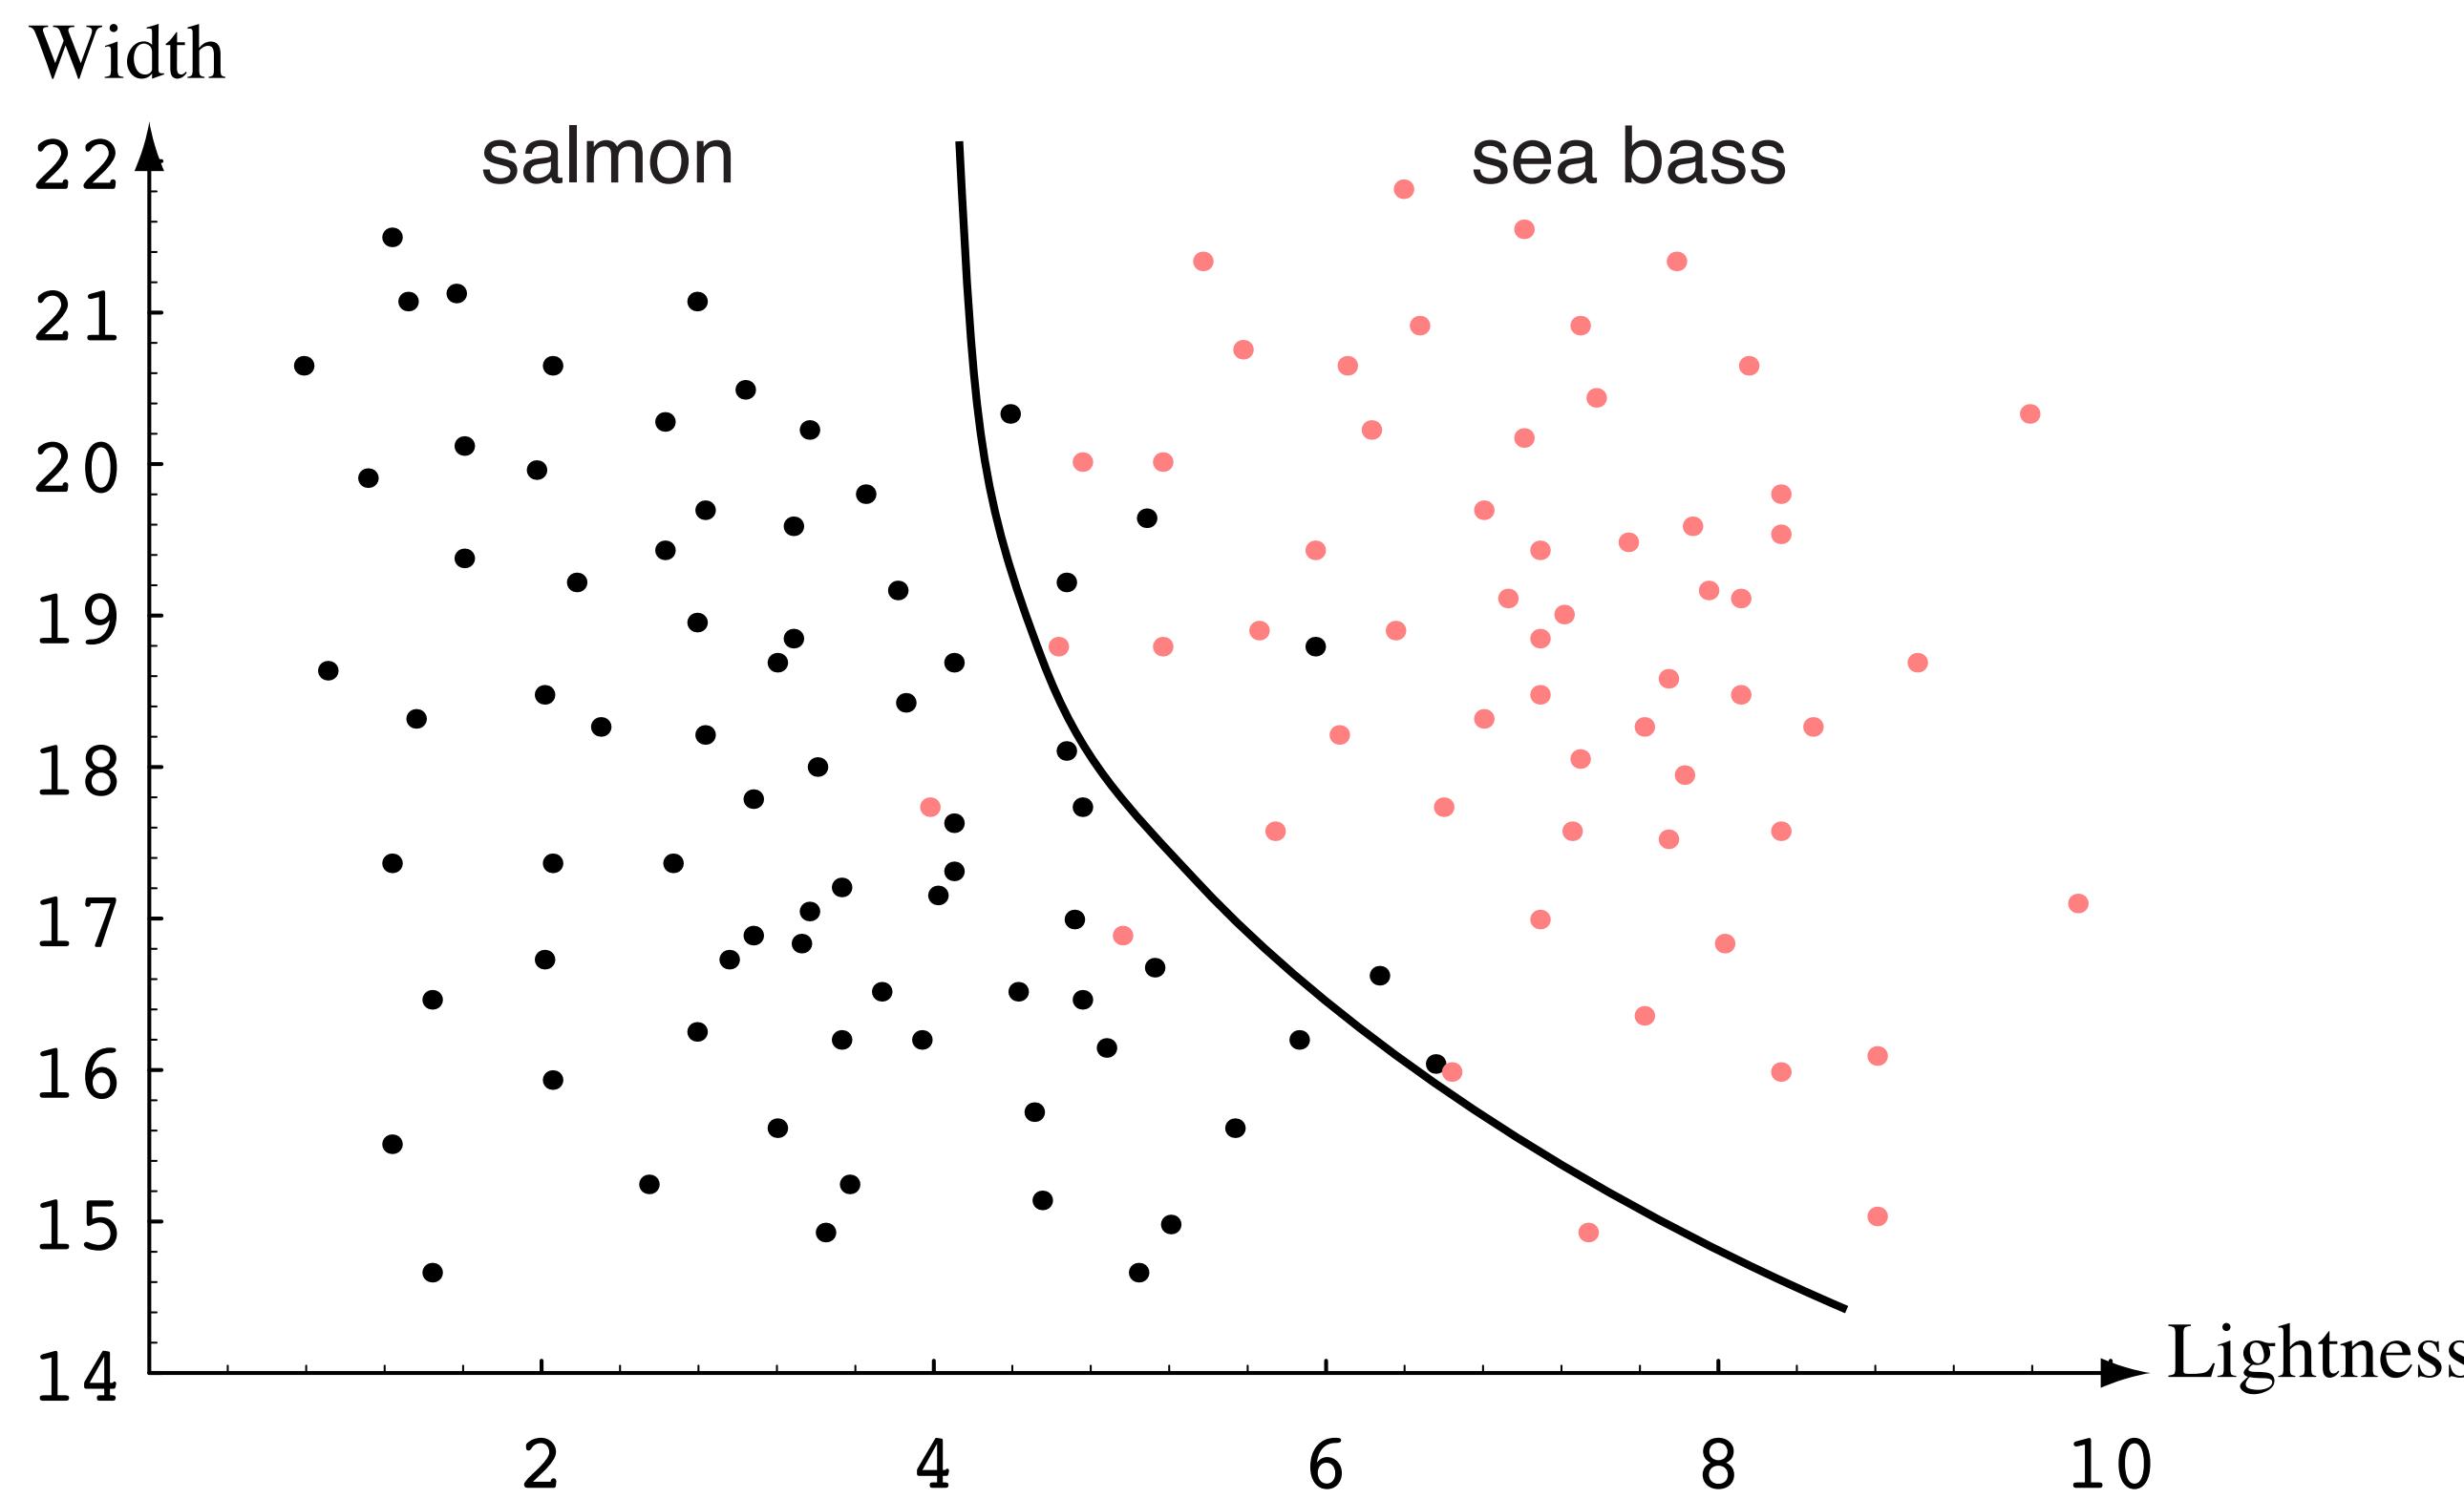
# Superfície de decisão



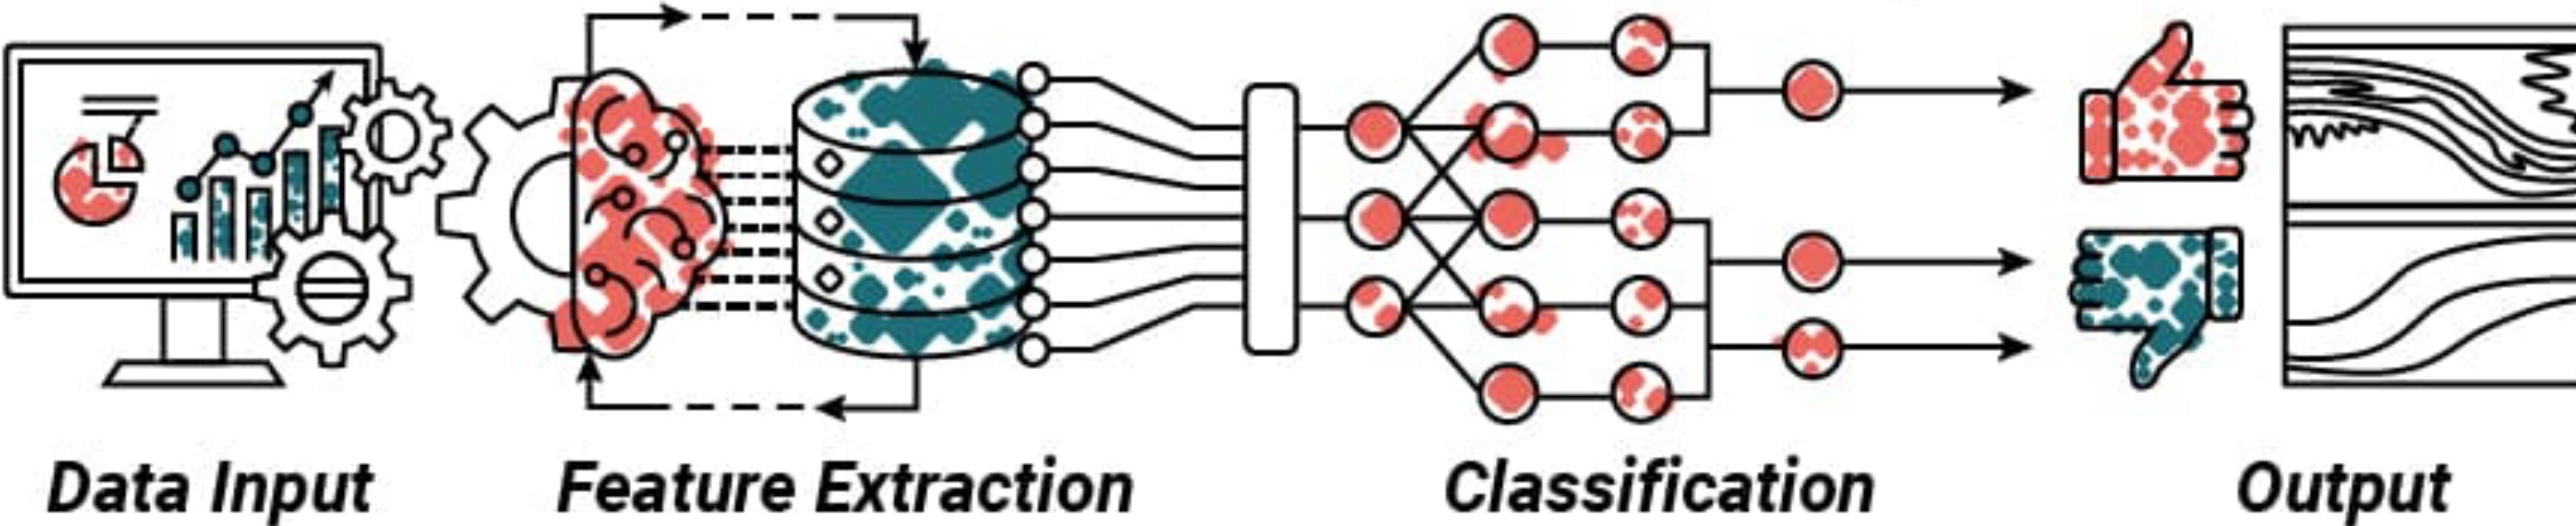
# Superfície de decisão (complexa)



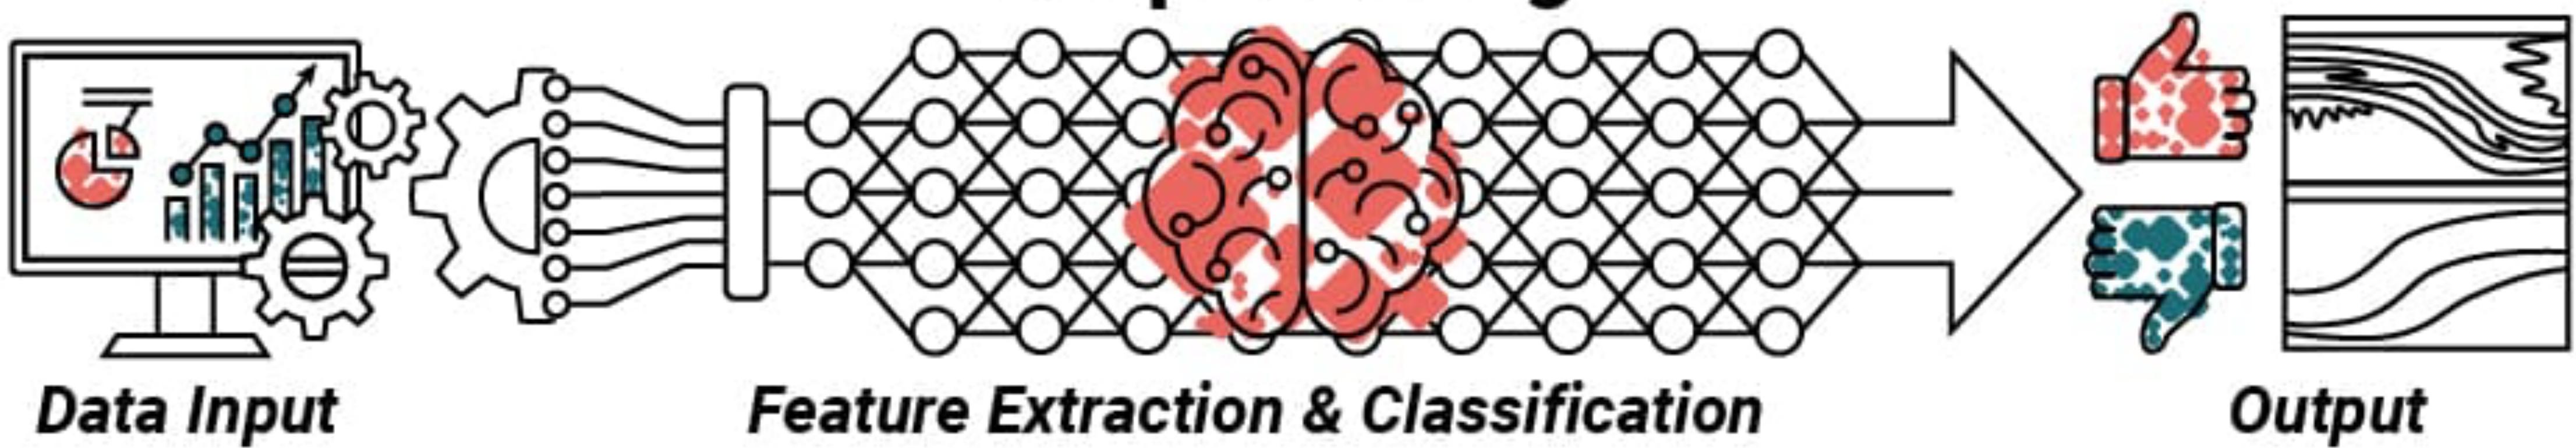
# Superfície de decisão (adequada)



## Traditional Machine Learning



## Deep Learning

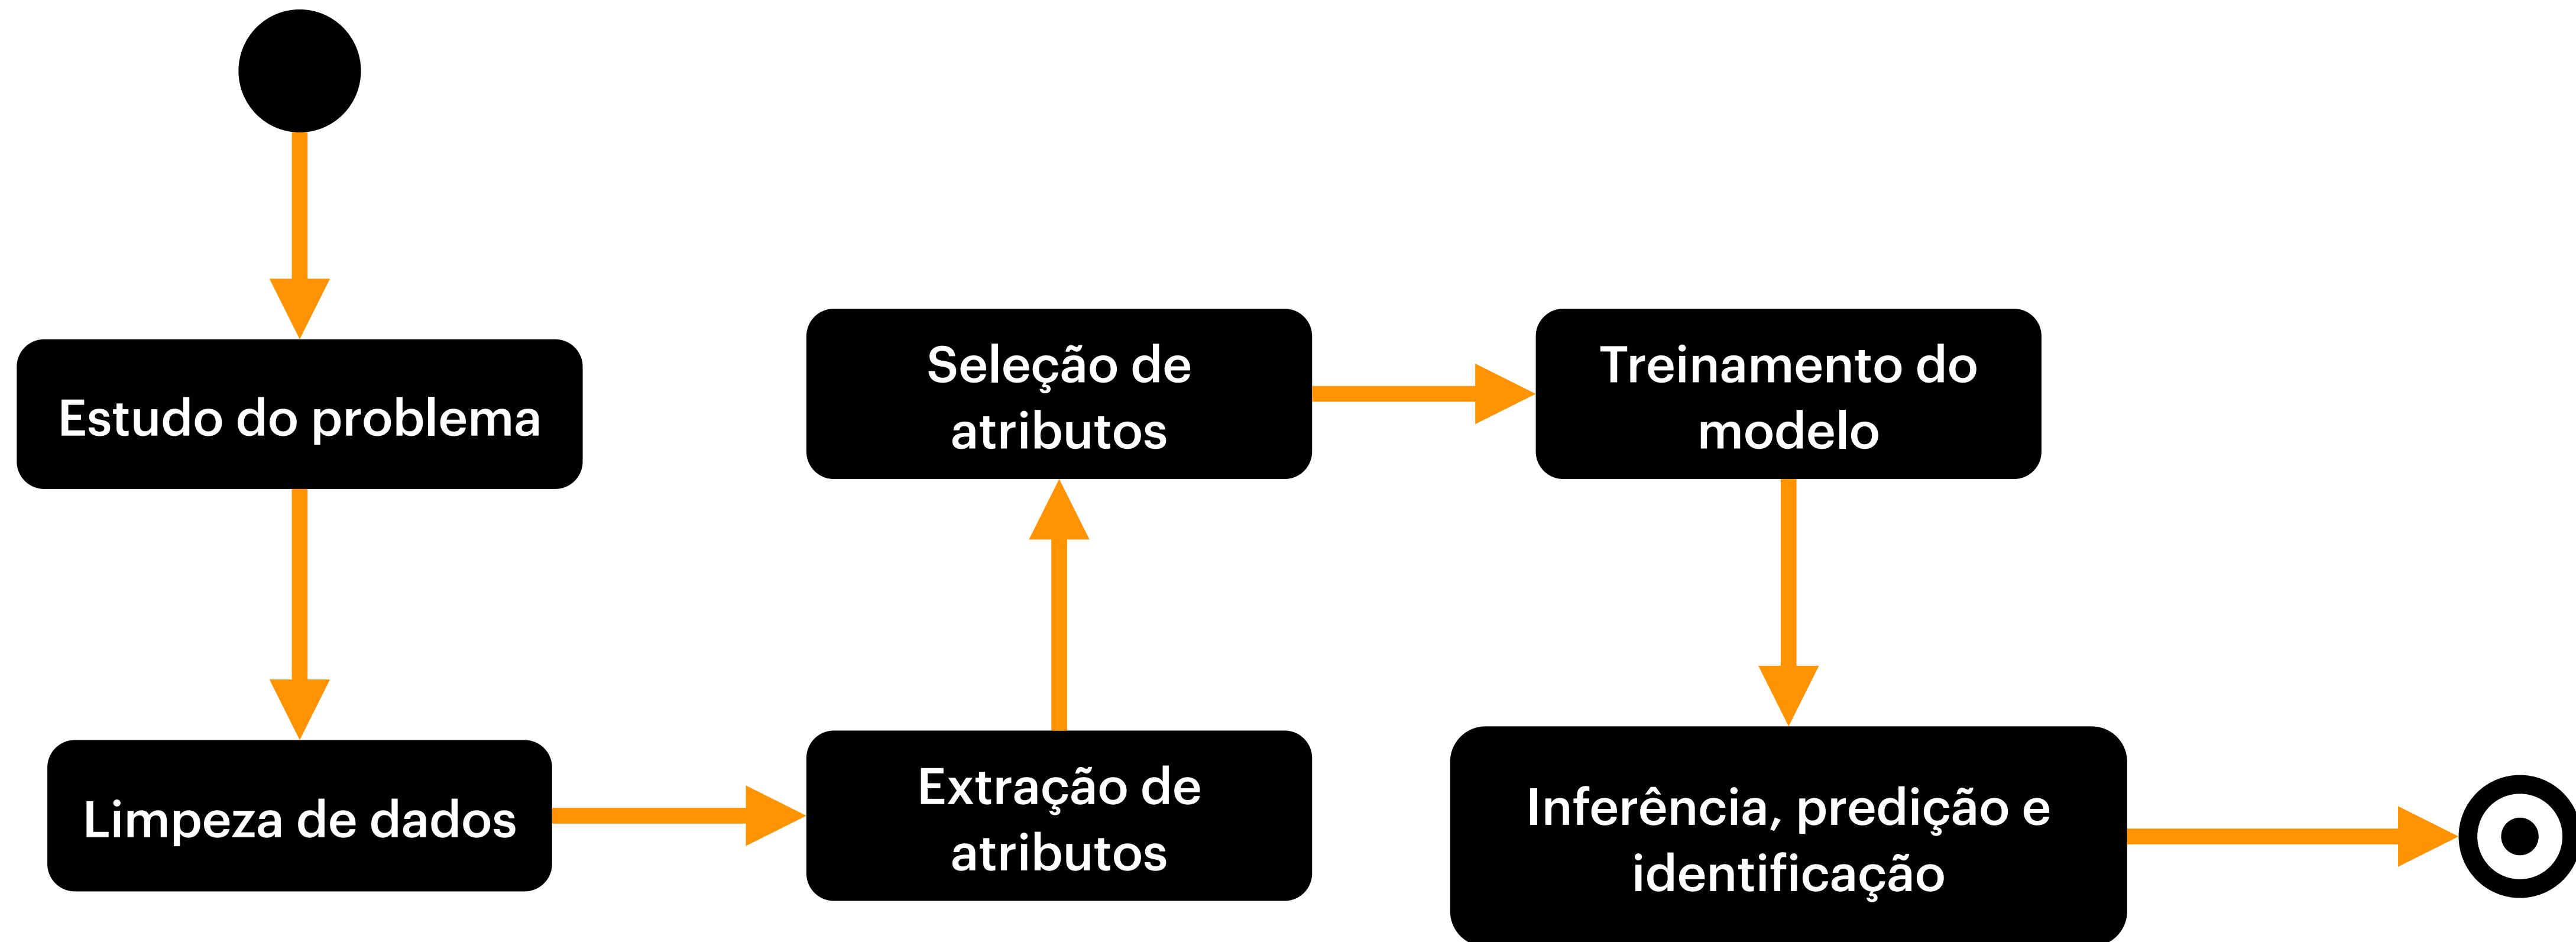


**Fonte:** <https://mosaicdatascience.com/2022/02/02/how-deep-learning-facilitates-automation-innovation-and-when-to-use-it/>

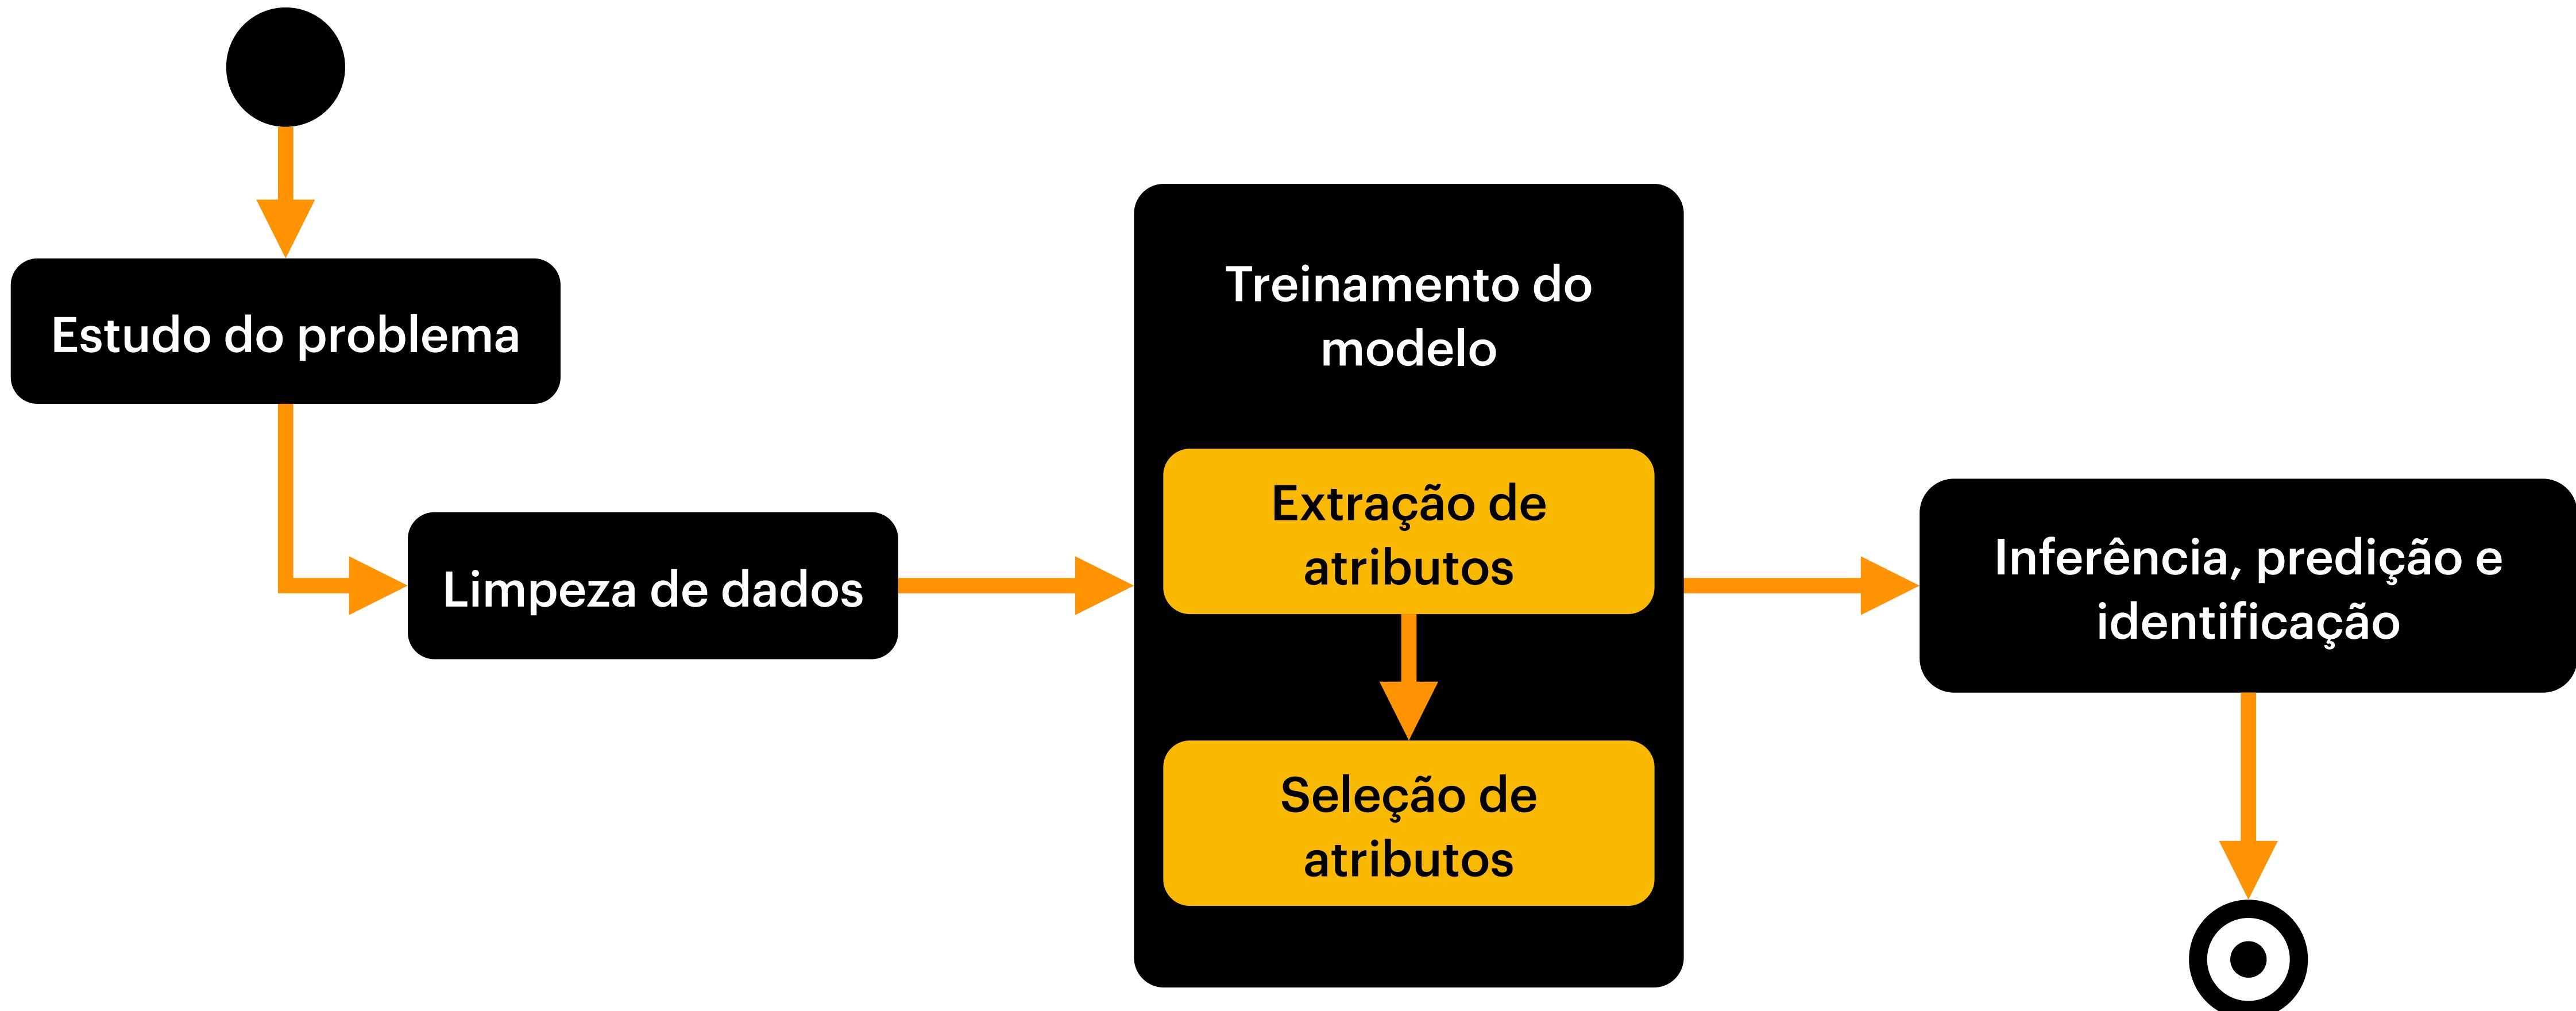
# Aprendizagem de máquina vs Aprendizagem Profunda

Tradicional	Profunda
Baixos requisitos de hardware no computador: Dada a quantidade limitada de computação, o computador, <b>geralmente, não precisa de uma GPU</b> para computação paralela.	Requisitos de hardware mais altos no computador: Para executar operações de matriz em <b>dados massivos</b> , o <b>computador precisa de uma GPU</b> (ou TPU) para executar a computação paralela.
Aplicável ao treinamento com uma <b>pequena quantidade de dados</b> e cujo desempenho <b>não pode ser melhorado continuamente à medida que a quantidade de dados aumenta</b> .	Cujo desempenho pode ser alto quando parâmetros de <b>peso de alta dimensão</b> e <b>dados de treinamento massivos</b> são fornecidos.
Detalhamento do problema nível por nível.	Aprendizagem ponto-a-ponto (E2E learning).
Seleção manual de atributos.	Extração automática de atributos.
Atributos fáceis de explicar.	Atributos (ainda) difíceis de explicar.

# Framework tradicional



# Framework apredizagem profunda



# Limpeza de dados

#	Id	Name	Birthday	Gender	IsTeacher	#Students	Country	City
1	111	John	31/12/1990	M	0	0	Ireland	Dublin
2	222	Mery	15/10/1978	F	1	15	Iceland	
3	333	Alice	19/04/2000	F	0	0	Spain	Madrid
4	444	Mark	01/11/1997	M	0	0	France	Paris
5	555	Alex	15/03/2000	Z	1	23	Germany	Berlin
6	555	Peter	1983-12-01	M	1	10	Italy	Rome
7	777	Calvin	05/05/1995	M	0	0	Italy	Italy
8	888	Roxane	03/08/1948	F	0	0	Portugal	Lisbon
9	999	Anne	05/09/1992	F	0	5	Switzerland	Geneva
10	101010	Paul	14/11/1992	M	1	26	Ytali	Rome

**Fonte:** Machine Learning Overview. Huawei, 2021.

# Limpeza de dados

#	Id	Name	Birthday	Gender	IsTeacher	#Students	Country	City
1	111	John	31/12/1990	M	0	0	Ireland	Dublin
2	222	Mery	15/10/1978	F	1	15	Iceland	
3	333	Alice		F	0			Madrid
4	444	Mark	01/11/1997	M	0	0	France	Paris
	555	Alex	15/03/2000	Z	1	23	Germany	Berlin
6	555	Peter	1983-12-01	M	1	10	Italy	Rome
7	777	Calvin	05/05/1995	M	0		Italy	
8		Xane	03/08/1948	F	0	0	Portugal	Lisbon
9	999	Anne	05/09/1992	F	0	5	Switzerland	Geneva
10	101010	Paul	14/11/14	M	1	26	Italy	Rome

Annotations:

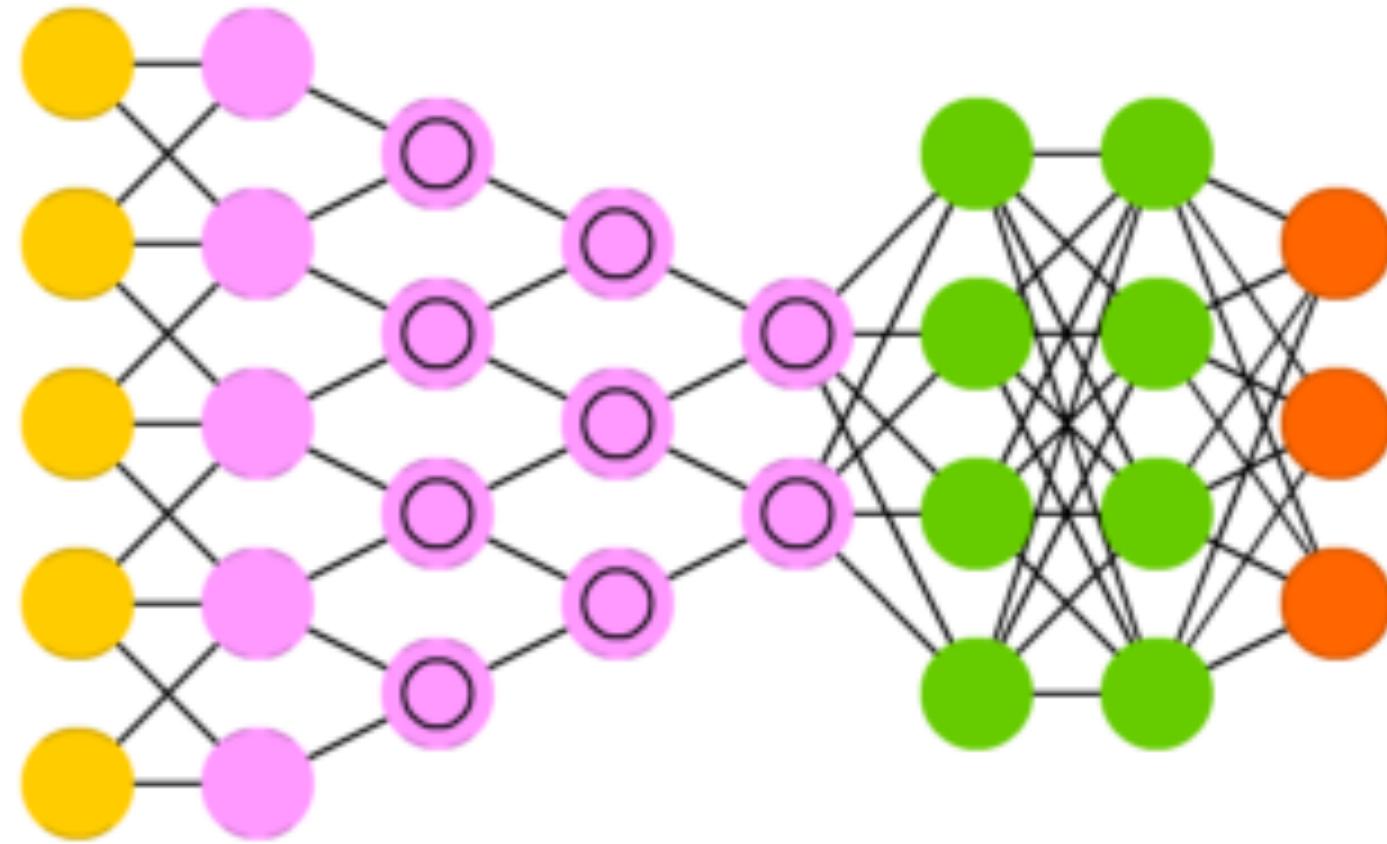
- Registro duplicado (Red box around Id 555)
- Valor inválido (Red box around Birthday in row 3)
- Valor faltante (Red box around #Students in row 3)
- Valor deveria estar em outra coluna (Red box around City in row 4)
- Formato inválido (Red box around Birthday in row 6)
- Valor inválido (Red box around Gender in row 7)
- Dependência inválida de atributo (Red box around City in row 10)

Fonte: Machine Learning Overview. Huawei, 2021.

# Algumas redes neurais

Normalmente, a arquitetura é uma rede neural profunda e o "Deep" em "deep learning" refere-se ao número de camadas da rede neural.

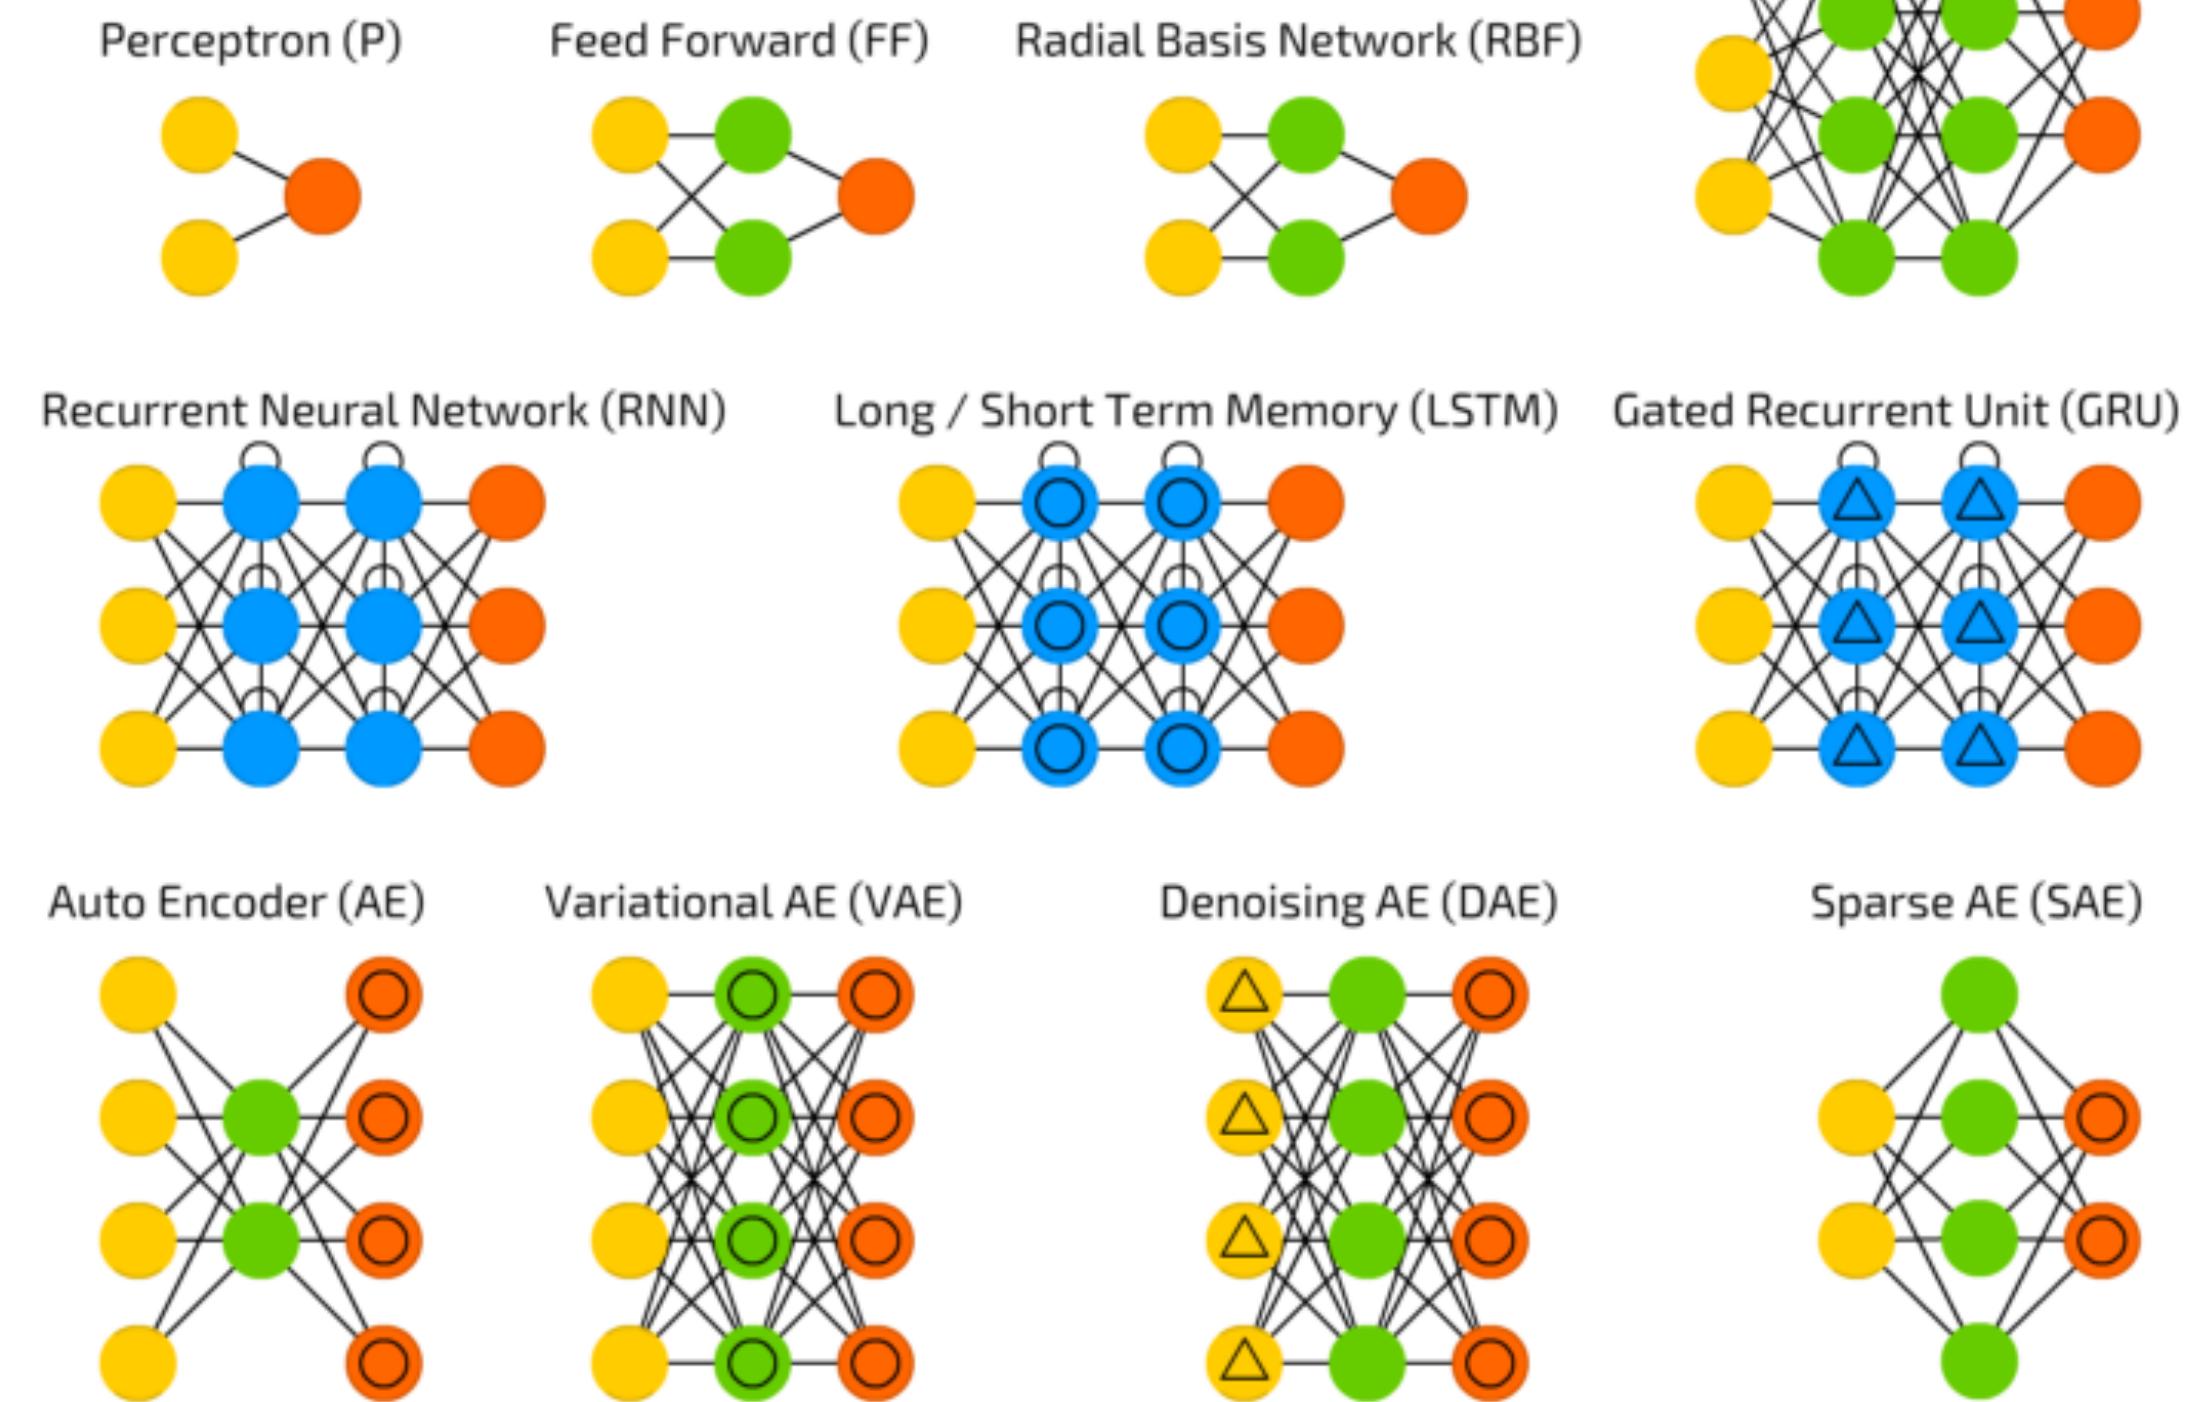
Deep Convolutional Network (DCN)



- Backfed Input Cell
- Input Cell
- △ Noisy Input Cell
- Hidden Cell
- Probabilistic Hidden Cell
- △ Spiking Hidden Cell
- Output Cell
- Match Input Output Cell
- Recurrent Cell
- Memory Cell
- △ Different Memory Cell
- Kernel
- Convolution or Pool

## *A mostly complete chart of* **Neural Networks**

©2016 Fjodor van Veen - asimovinstitute.org



**Fonte:** <https://medium.com/predict/the-complete-list-to-make-you-an-ai-pro-be83448720b8>

# Referências

- Felp Roza. **End-to-end learning, the (almost) every purpose ML method.** 2019. Disponível em: <https://towardsdatascience.com/e2e-the-every-purpose-ml-method-5d4f20daf4e4>. Acessado em mar, 2023.
- HUAWEI. Deep Learning Overview. 2020, Accessed on Mar 2023.
- Guilherme A. Barreto. **Introdução à Classificação de Padrões.** Grupo de Aprendizado de Máquinas – GRAMA, 2021.
- Richard O. Duda, Peter E. Hart, David G. Stork. **Pattern Classification.** John Wiley & Sons, 2012.