

**INSTITUTO FEDERAL**  
Ceará

Programa de Pós-Graduação  
em Ciência da Computação

# 03 ADaptive LINear Element

## APRENDIZAGEM PROFUNDA

PPGCC – 2023.1

Prof. Saulo Oliveira <[saulo.oliveira@ifce.edu.br](mailto:saulo.oliveira@ifce.edu.br)>




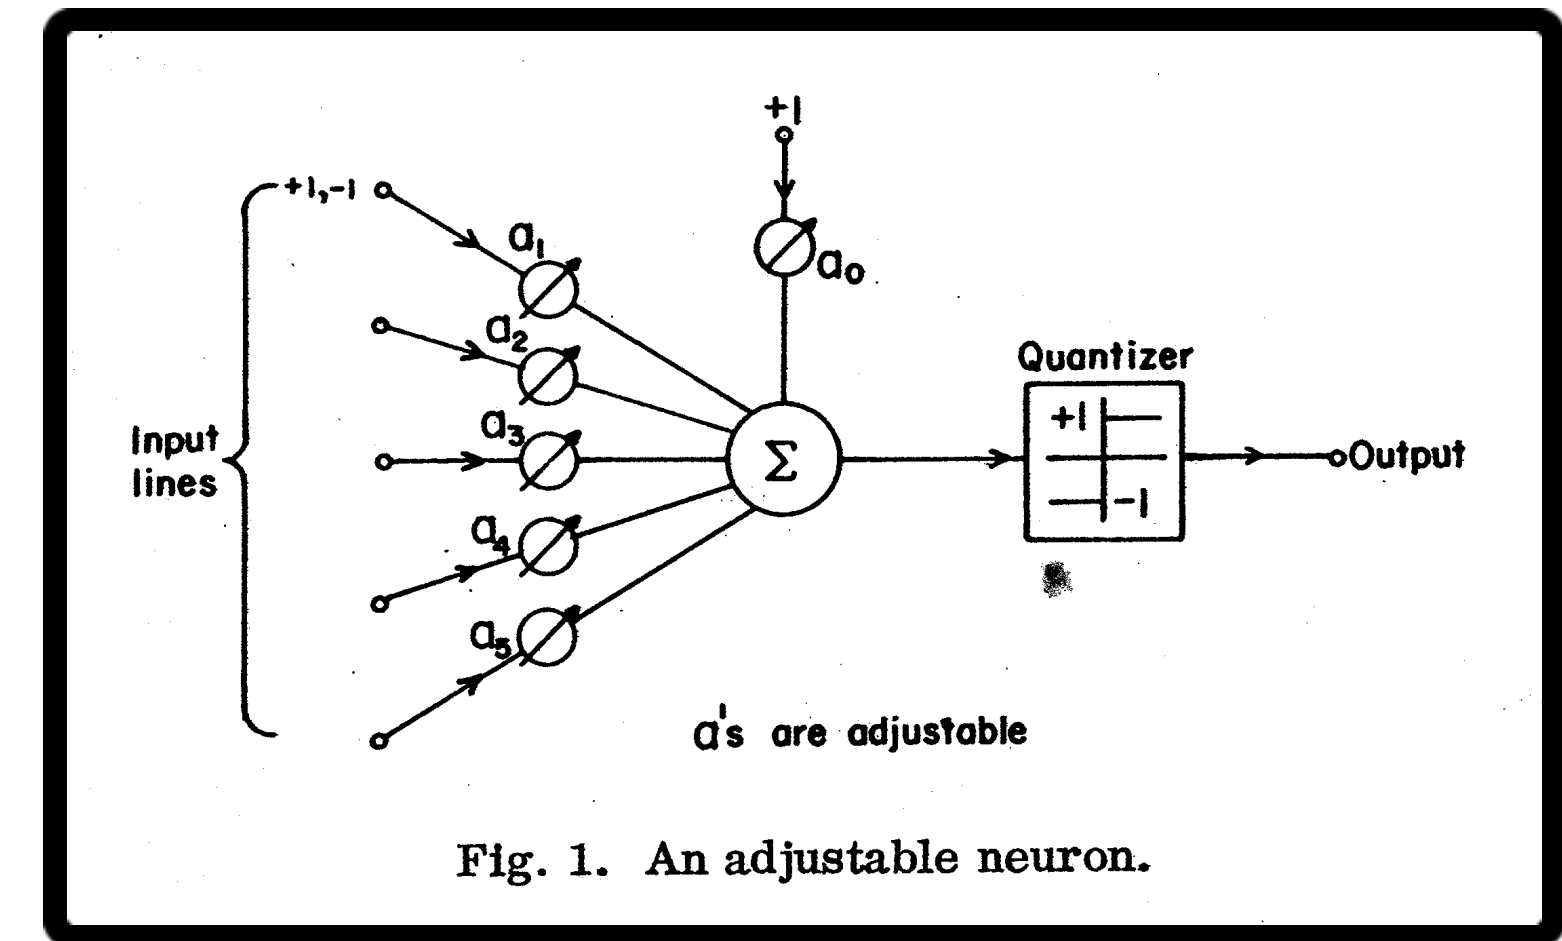
# ADALINE

- Em 1960 , o Elemento Linear Adaptativo (ADaptive LINear Element — ADALINE) surgiu na literatura quase que simultaneamente com o Perceptron, no trabalho:

B. Widrow and M. E. Hoff. Adaptive switching circuits. In IRE WESCON Convention Record-Part 4, pages 96-104, 1960.

- A operação é não-linear do tipo degrau para o Perceptron. Enquanto, a operação é puramente linear para o ADALINE.

$$\hat{f}(\mathbf{x}) = \mathbf{w}^T \mathbf{x} = u.$$



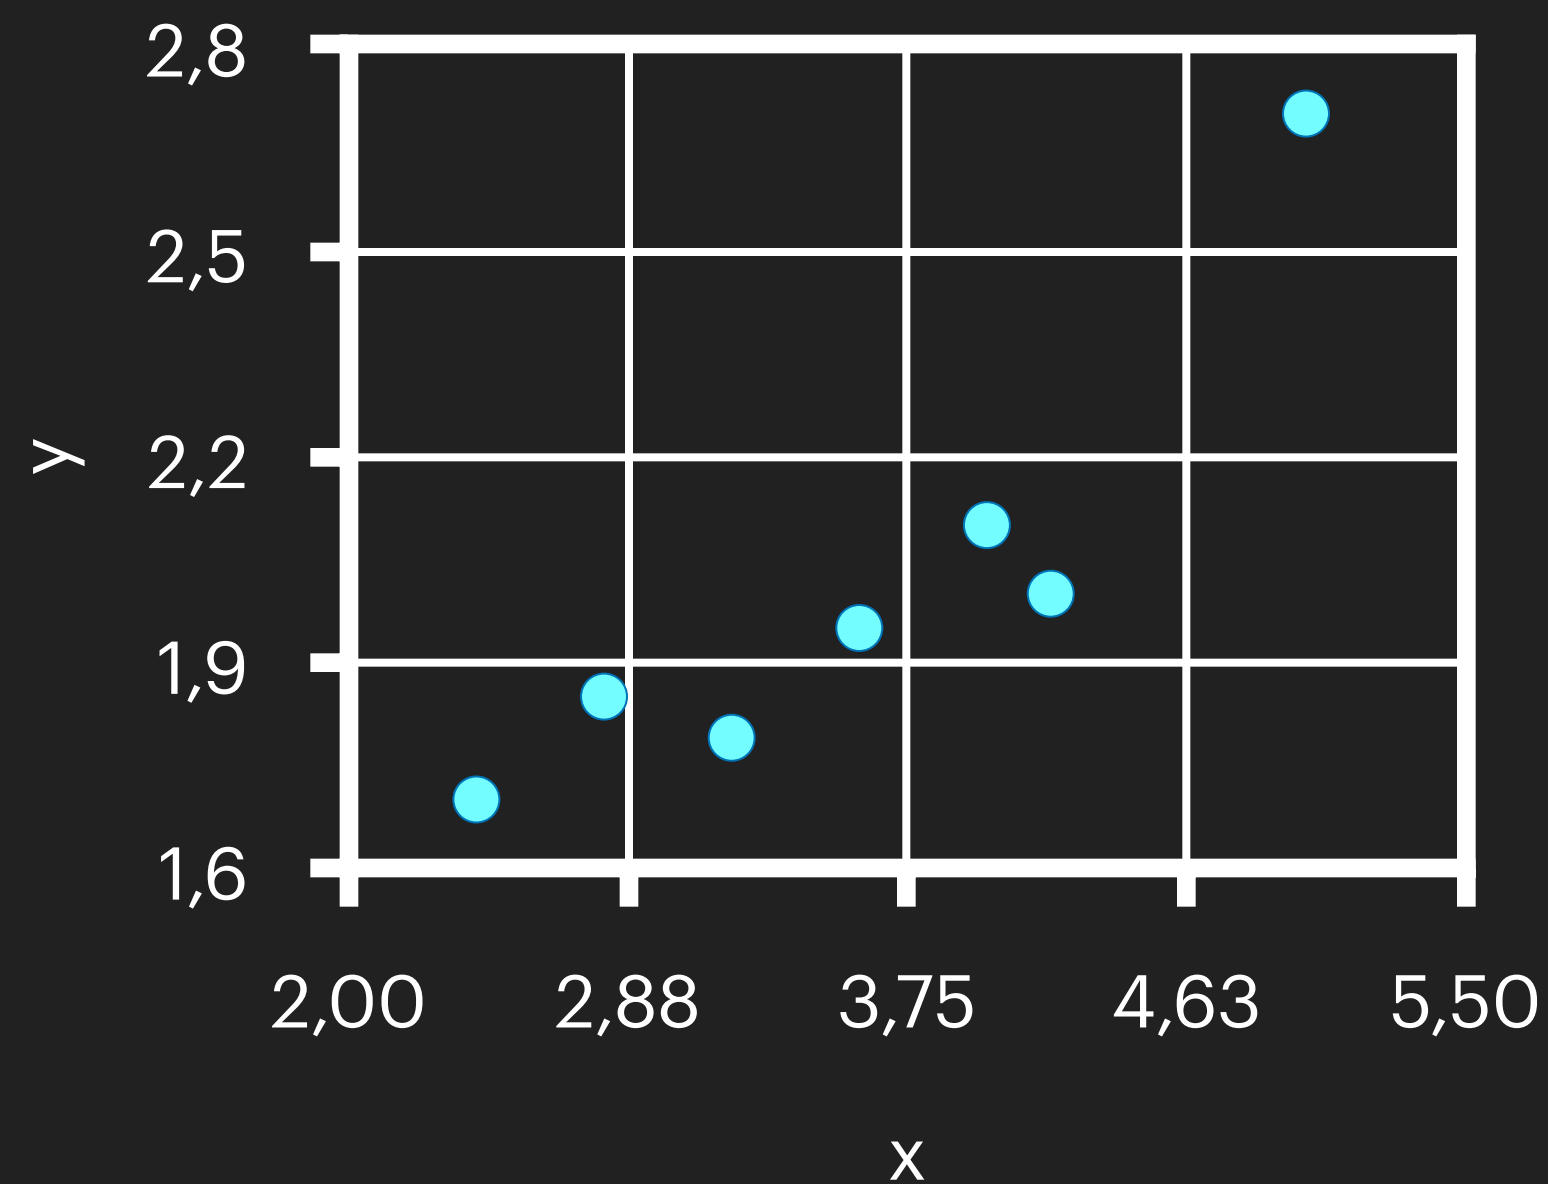
**COMO QUE TREINA  
UM ADALINE?**

# TREINANDO UM ADALINE

- Premissa básica: achar o vetor de pesos que minimize o TODOS os erros;
- Forma de calcular o erro continua a mesma, i.e.,  $e = d - y = d - \mathbf{x}^T \mathbf{w}$ .
- Como agregar TODOS os erros em uma função só?

# **FUNÇÃO DE PERDA/CUSTO/ OBJETIVO**


# TREINANDO UM ADALINE



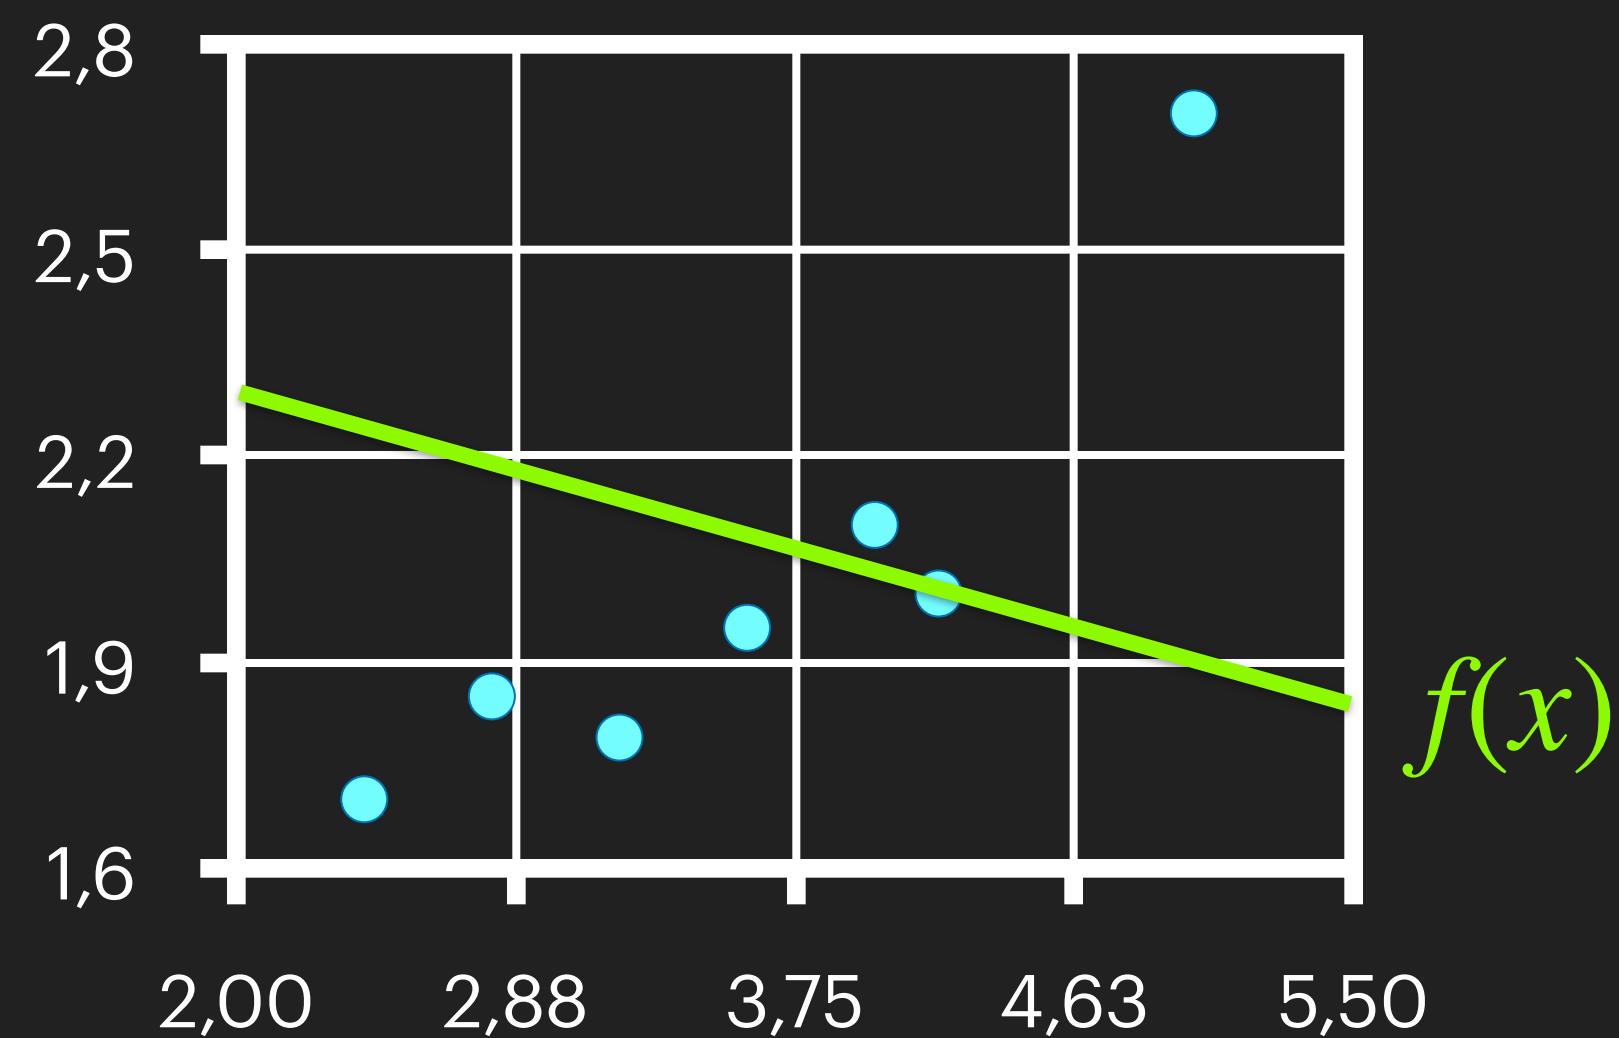
x	y
2,40	1,70
2,80	1,85
3,20	1,79
3,60	1,95
4,00	2,10
4,20	2,00
5,00	2,70

**Qual a relação  
entre  $x$  e  $y$ ?**

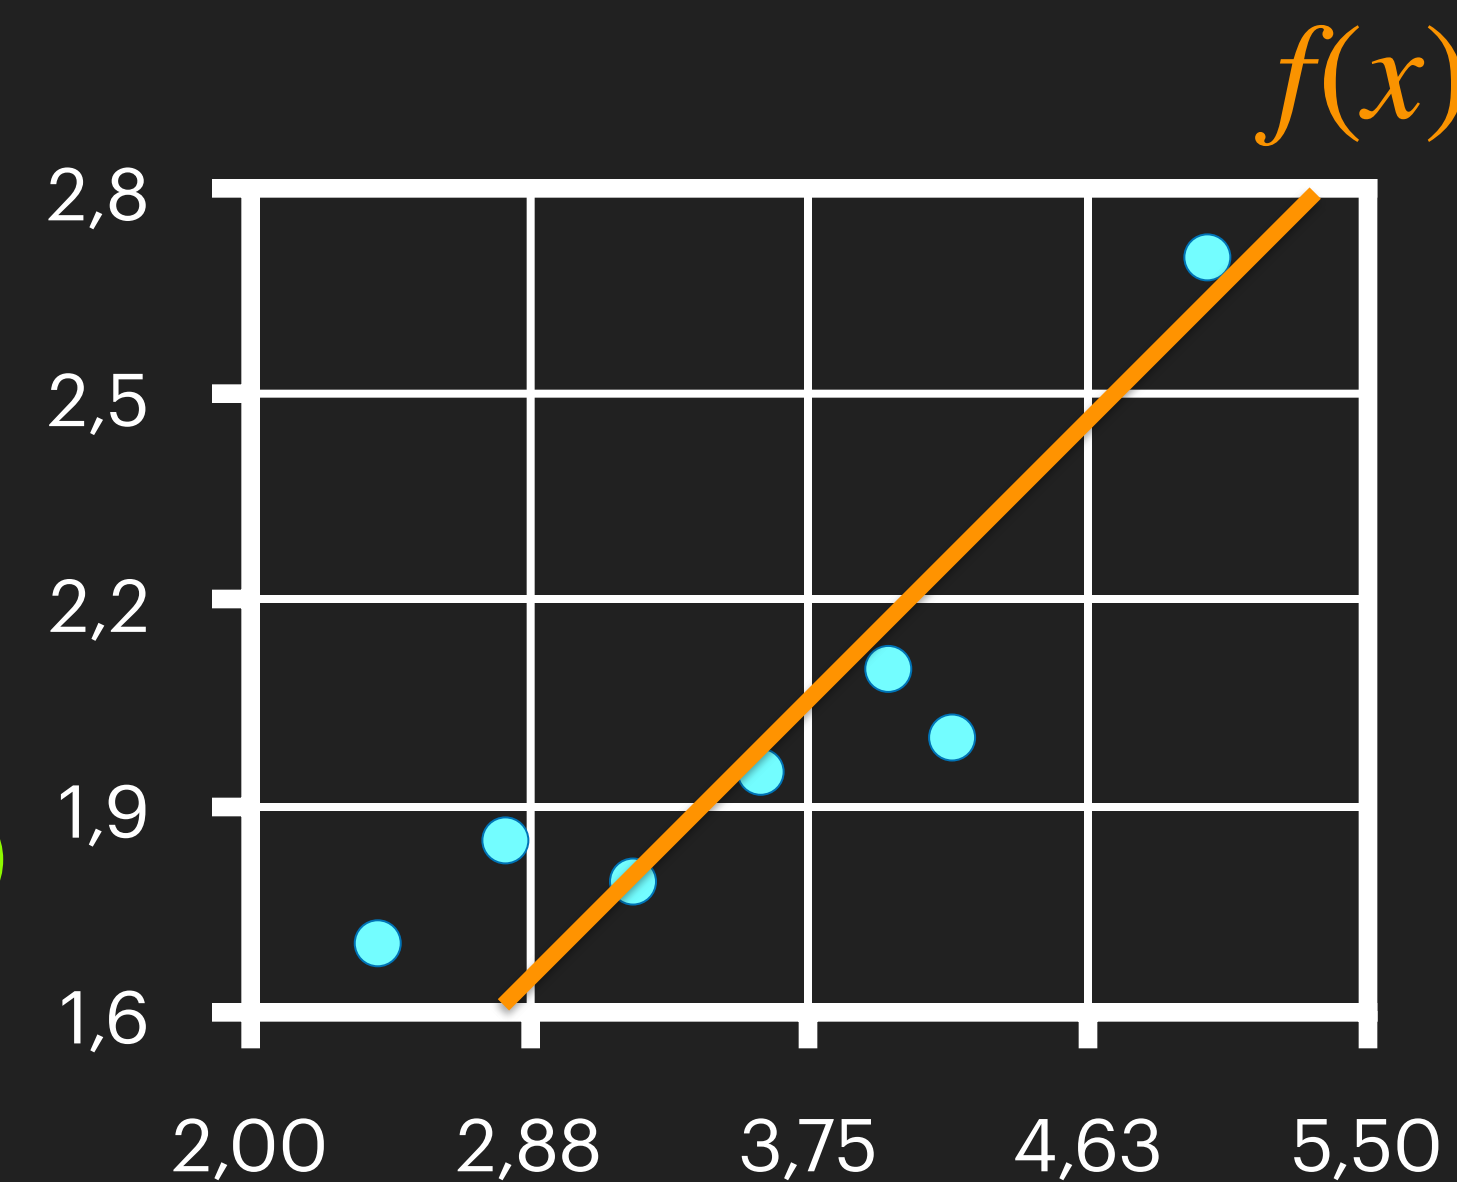
# TREINANDO UM ADALINE



$$f(x) = 0,92x - 1, \text{ i.e.,}$$
$$\mathbf{w} = [-1, 0.92]$$

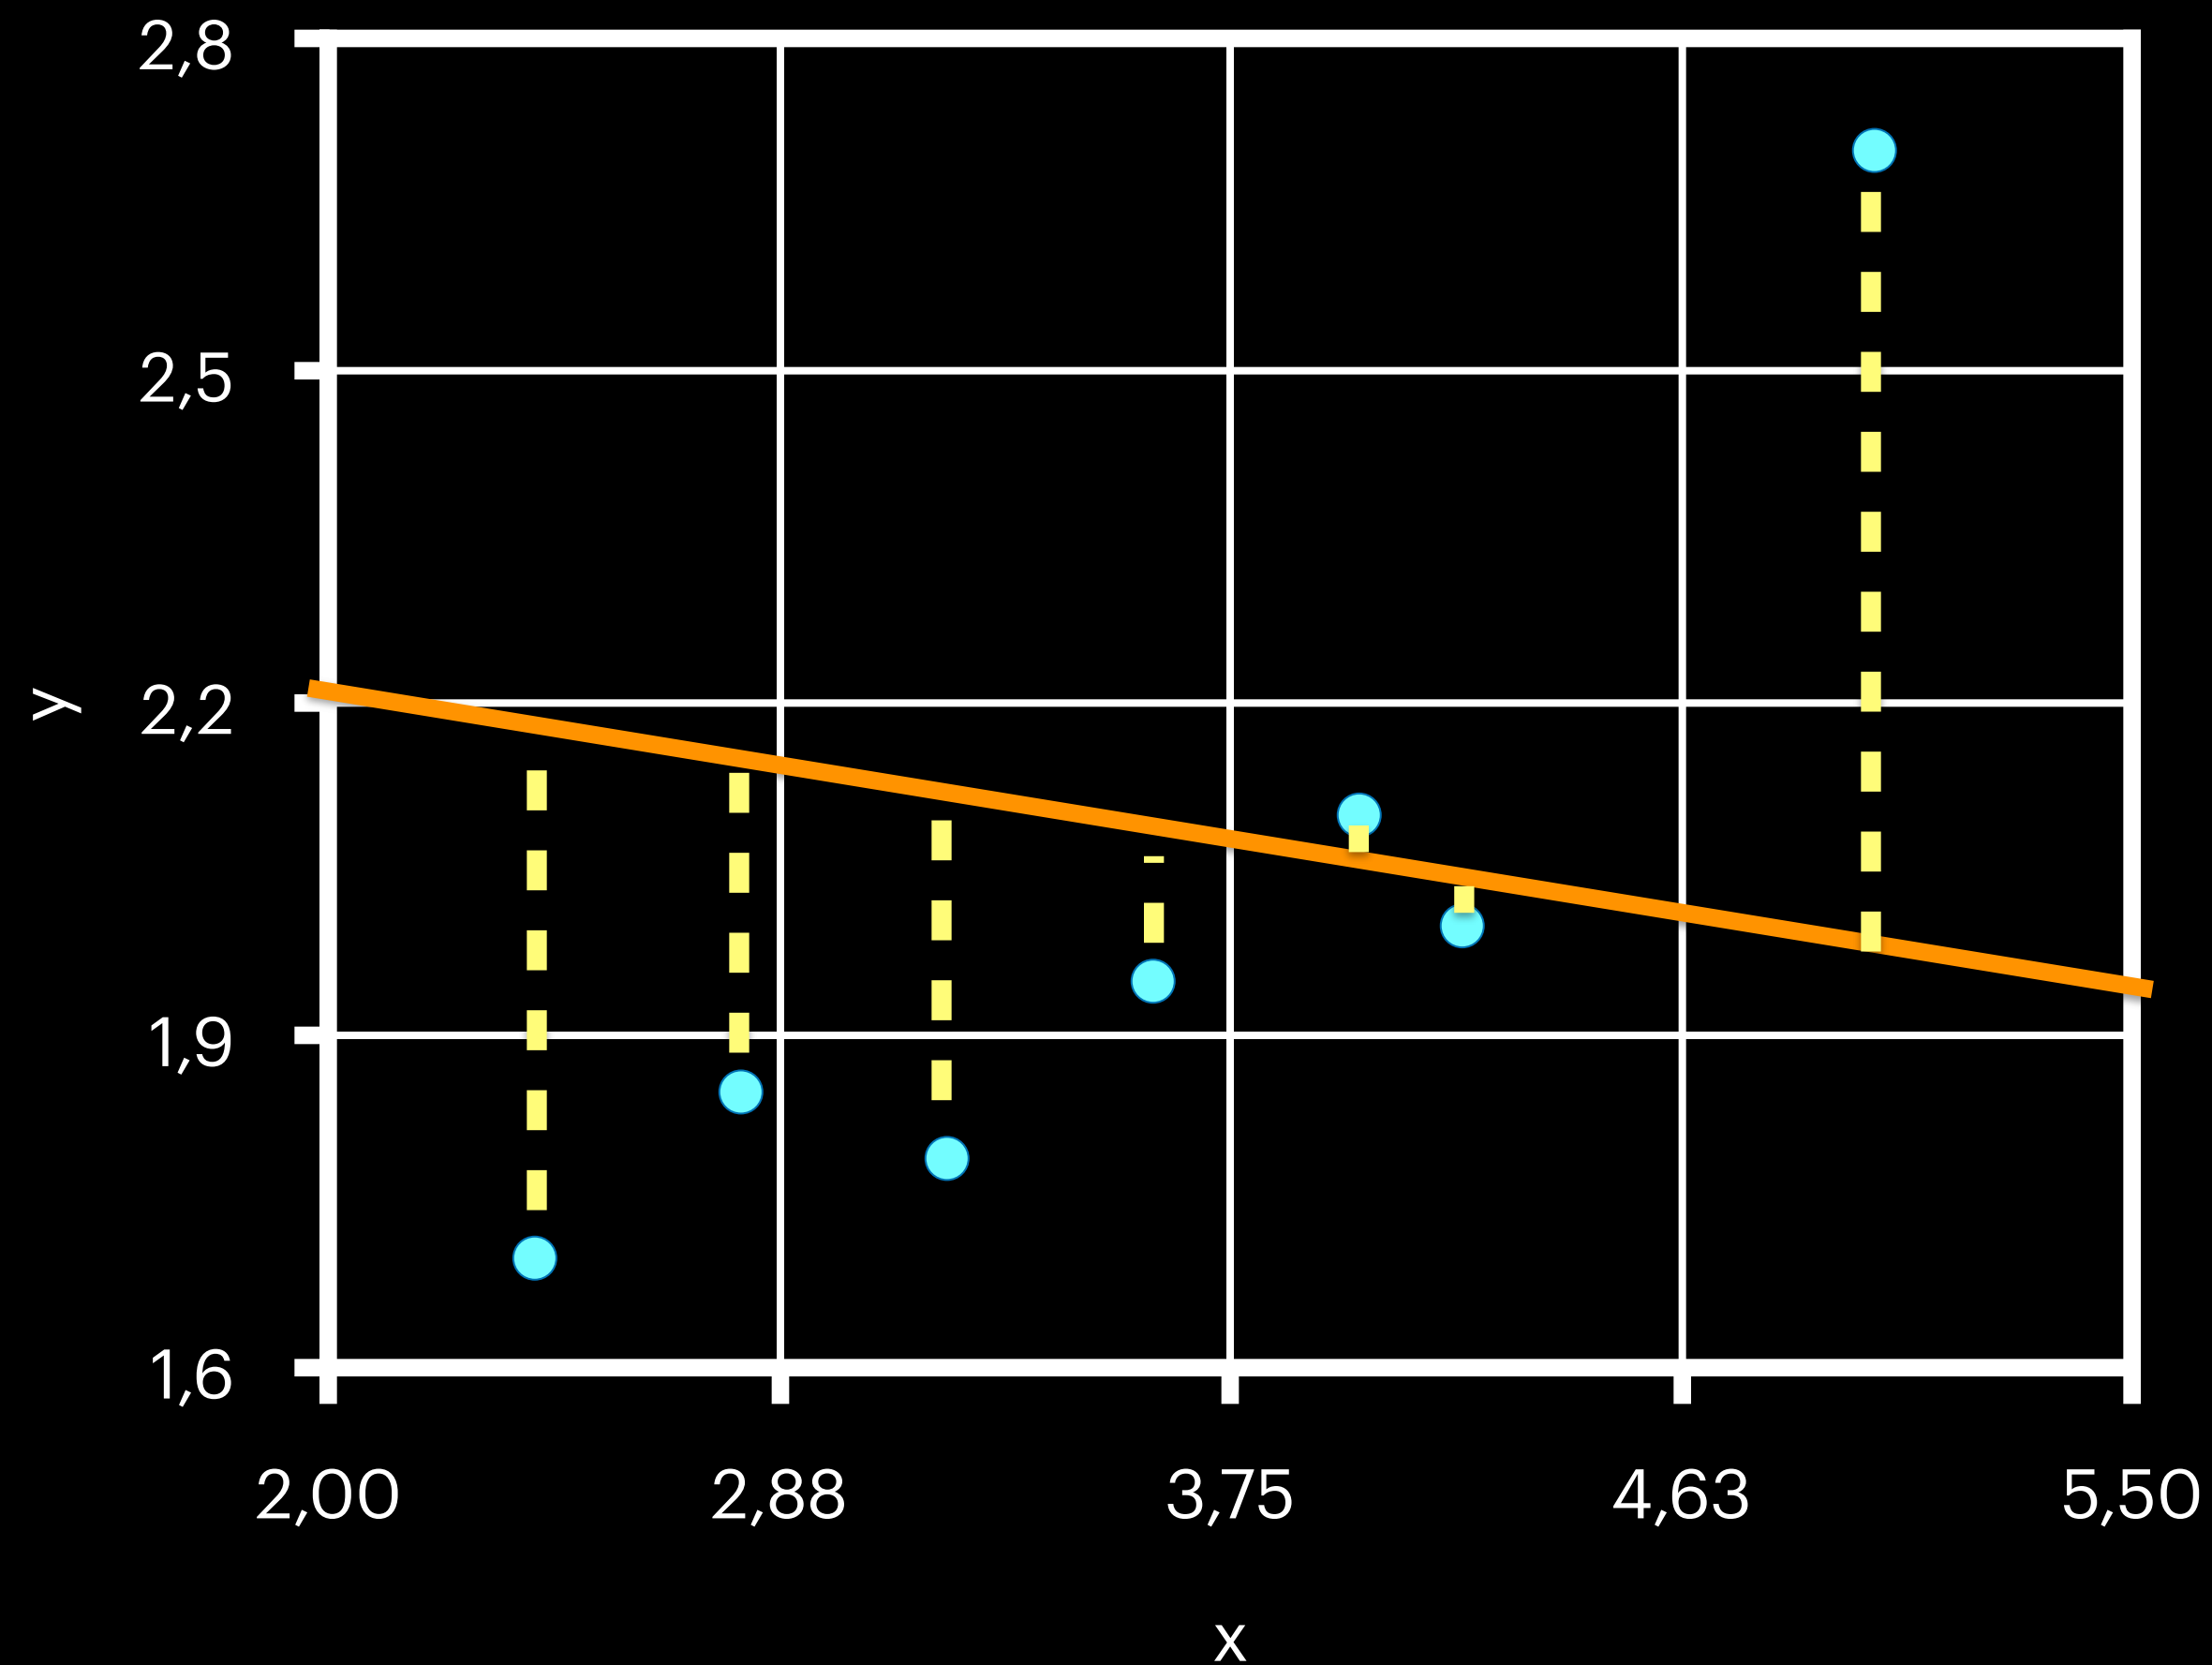


$$f(x) = 0,11x + 2,5, \text{ i.e.,}$$
$$\mathbf{w} = [2.5, 0.11]$$



$$f(x) = 0,52x - 0,1, \text{ i.e.,}$$
$$\mathbf{w} = [0.10, 0.52]$$

# FUNÇÃO DE PERDA/CUSTO/OBJETIVO




Embora existam muitas funções de perda, todas elas essencialmente computam o desempenho do modelo com base na dissimilaridade entre o valor previsto e seu valor real em um conjunto de dados, ou seja, o ERRO!

$$MSE(f) = \sum_i e_i^2.$$




# ERRO QUADRÁTICO MÉDIO

$$MSE(f) = \frac{1}{n} \sum_i e_i^2 = \frac{1}{n} \sum_i (y_i - f(x_i))^2 = \frac{1}{n} \sum_i (y_i - \mathbf{x}_i^T \mathbf{w})^2$$



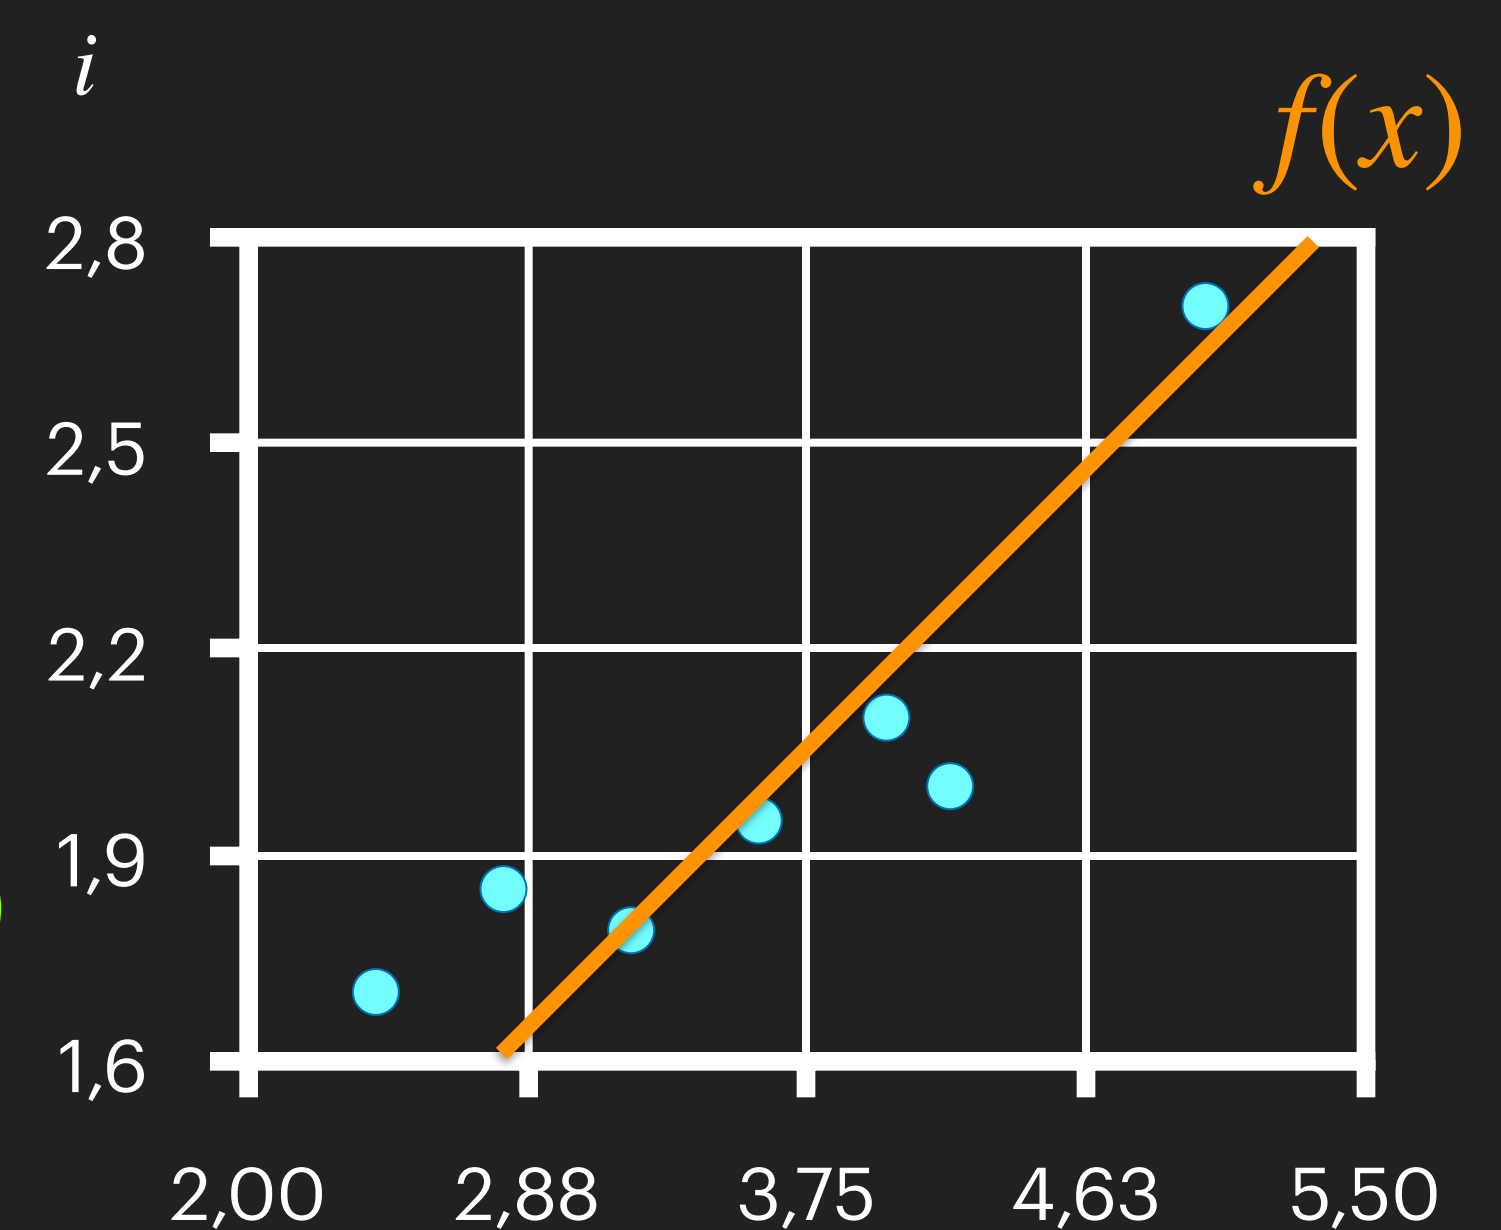
$$MSE(f) = 0,17$$

$$f(x) = 0,92x - 1, \text{ i.e., } \mathbf{w} = [-1, 0.92]$$



$$MSE(f) = 0,08$$

$$f(x) = 0,11x + 2,5, \text{ i.e., } \mathbf{w} = [2.5, 0.11]$$



$$MSE(f) = 0,02$$

$$f(x) = 0,52x - 0,1, \text{ i.e., } \mathbf{w} = [0.10, 0.52]$$

# TREINANDO UM ADALINE (Recap)


- Premissa básica: achar o vetor de pesos que minimize o TODOS os erros;
- Forma de calcular o erro continua a mesma, i.e.,  $e = d - y = d - \mathbf{x}^T \mathbf{w}$ .
- Como agregar TODOS os erros em uma função só?

$$J(\mathbf{e}) = \sum e_i^2.$$

$$J(\mathbf{w}) = \sum_i (d_i - \mathbf{x}_i^T \mathbf{w})^2.$$

$$J(\mathbf{w}) = \sum_i d_i^2 - 2d_i \mathbf{x}_i^T \mathbf{w} + (\mathbf{x}_i^T \mathbf{w})^2.$$


$$\mathbf{w}^* = \min_{\mathbf{w}} J(\mathbf{w})$$



# TREINANDO UM ADALINE (Recap)

- Com o intuito de minimizar  $J(\mathbf{w})$ , é necessário que seja obtido a direção do ajuste a ser aplicado no vetor de pesos para aproximar a solução do mínimo de  $J(\mathbf{w})$ ;
- De modo iterativo, iremos realizar  $\mathbf{w}^{(t+1)} = \mathbf{w}^{(t)} + \Delta \mathbf{w}$ ;
- Para tal, usa-se o **gradiente** da função  $J(\mathbf{w})$  no ponto  $\mathbf{w}^{(t)}$ ;
- Sabe-se que o gradiente possui a mesma direção da maior variação do erro (aponta na direção do crescimento da função). Portanto, o ajuste deve ocorrer na direção contrária do gradiente. Logo a variação dos pesos pode ser descrita como:

$$\Delta \mathbf{w} \propto - \nabla \mathbf{w}.$$



# TREINANDO UM ADALINE (Pulo do )

- Sabe-se que a função  $J$  depende de  $e$ , bem como sabe-se que  $e$  depende de  $y$  e, ainda, sabe-se que  $y$  depende de  $\mathbf{w}$ ;
- Cada componente do gradiente da função custo  $\nabla J$  pode ser obtida com base na regra da cadeia, a saber,

$$\frac{\partial J}{\partial w_i} = \frac{\partial J}{\partial e} \frac{\partial e}{\partial y} \frac{\partial y}{\partial w_i}$$

- Quanto valem os termos abaixo?

a)  $\frac{\partial J}{\partial e}$

b)  $\frac{\partial e}{\partial y}$

c)  $\frac{\partial y}{\partial w_i}$

d)  $\frac{\partial J}{\partial w_i}$

# TREINANDO UM ADALINE (Pulo do )

- Considerando que



$$\text{a) } \frac{\partial J}{\partial e} = e \quad \text{b) } \frac{\partial e}{\partial y} = -1 \quad \text{c) } \frac{\partial y}{\partial w_i} = x_i \quad \text{d) } \frac{\partial J}{\partial w_i} = e(-1)x_i = -ex_i.$$

- Considerando também a regra de aprendizagem  $\mathbf{w}^{(t+1)} = \mathbf{w}^{(t)} + \Delta \mathbf{w}$ ;

- Considerando que  $\Delta \mathbf{w} \propto \nabla J$  e que  $\frac{\partial J}{\partial \mathbf{w}} = -\mathbf{x}e$ , podemos reescrever a regra de atualização da seguinte forma:

$$\mathbf{w}^{(t+1)} = \mathbf{w}^{(t)} + \eta e^{(t)} \mathbf{x}$$

# TREINANDO UM ADALINE (Pulo do 🐱)



# Referências

- Richard O. Duda, Peter E. Hart, David G. Stork. **Pattern Classification**. John Wiley & Sons, 2012.
- Guilherme A. Barreto. **Introdução à Classificação de Padrões**. Grupo de Aprendizado de Máquinas – GRAMA, 2021.
- KDNuggets. **Neural Networks with Numpy for Absolute Beginners — Part 2: Linear Regression**. <https://www.kdnuggets.com/2019/03/neural-networks-numpy-absolute-beginners-part-2-linear-regression.html/2>, março de 2019. Acessado em Março de 2022.